


Preparación de Datos

Limpieza y preparación de datos

En 2009 Mike Driscoll (data scientist y CEO de Metamarkets) popularizó el término "**data munging**" para referirse al **arduo proceso de limpiar, preparar y validar los datos**.

¿Cómo invierte su tiempo un data scientist?





Limpieza de Datos




Resolver problemas de formato y asignar los tipos correctos de datos:

Por ejemplo cuando al pasar de CSV a Pandas una fecha no se importa correctamente. Ej:
20090609231247 en lugar de 2009-06-09 23:12:47.



Estandarizar categorías:

Cuando los datos se recolectaron con un sistema que no tiene los valores tipificados, valores que representan las mismas categorías pueden estar expresados de forma distinta, por ejemplo Arg, AR y Argentina.



Limpieza de Datos



Corregir valores erróneos:

Por ejemplo un valor numérico o inválido para describir el género. O una edad representada por un número negativo o mucho mayor que 100



Completar datos faltantes:


Los datasets del mundo real suelen venir con datos faltantes que responden a información que se perdió o nunca se recolectó.

Existen varias técnicas para completar datos faltantes. Al proceso de completar datos faltantes se lo llama "**imputación**".




Organizar correctamente el dataset:

Es importante estructurar las filas y columnas de la forma más conveniente. Para hacerlo se pueden aplicar las reglas del "**tidy data**".



¿Por qué
normalizar?

Manejo de cantidades en diferentes unidades o escalas.
Para no favorecer a ninguna variable en particular al calcular la distancia, debemos estandarizar y deshacernos de las unidades.



¿Qué es un hiperparámetro?

En machine learning, un hiperparámetro es un parámetro cuyo valor se utiliza para controlar el proceso de aprendizaje. Por el contrario, los valores de los parámetros se derivan a través del entrenamiento.

Los hiperparámetros se pueden clasificar como:

- hiperparámetros de modelo
- hiperparámetros de algoritmo

Diferentes algoritmos de aprendizaje requieren diferentes hiperparámetros, algunos algoritmos simples (como la regresión de mínimos cuadrados ordinarios) no requieren ninguno.


Por ejemplo, LASSO es un algoritmo que agrega un hiperparámetro de regularización a la regresión de mínimos cuadrados ordinarios, que debe establecerse antes de estimar los parámetros a través del algoritmo de entrenamiento.

(Puede ser que no quede claro en este momento este ejemplo, pero lo será en unas pocas clases)

Usando hiperparámetros distintos podemos crear instancias distintas de la misma clase del modelo seleccionado.

Los valores de los hiperparámetros deben ser establecidos antes de que el modelo sea ajustado a los datos.

Una misma clase de modelo con dos configuraciones de hiperparámetros distintas puede llevar a resultados muy disímiles entre sí.




Preparar los datos en una matriz de features y un vector target

Como vimos anteriormente, para el caso del aprendizaje supervisado requerimos la matriz de features (las columnas con las características de las observaciones) y una variable target con los labels que representan la clasificación de cada observación.

La matriz de features, X , puede ser un array bidimensional de Numpy o un DataFrame de Pandas, mientras que el vector objetivo, y , puede ser un array de Numpy o una Series de Pandas.

Para los modelos de aprendizaje no supervisado, no se requiere este paso.





Separar los sets de entrenamiento y de testing

El objetivo de un modelo de machine learning es generalizar a partir de lo aprendido, y ser capaz predecir la variable target de observaciones nunca antes vistas por el modelo.

Entonces el modelo debe aprender primero a partir de los datos que disponemos.

Y para evaluar qué tan buenas resultan sus predicciones, podemos comparar los valores reales y los que predice.

Para tener noción de cómo se comporta frente a datos nunca antes vistos dividimos nuestros datos en dos conjuntos disjuntos: entrenamiento y testing.





Preparar los datos en una matriz de features y un vector target

Para resolver este problema, vamos a dividir los datos de X en un training set y un testing set. El modelo aprenderá a partir de los datos del training set.

Luego del entrenamiento, aplicamos el modelo a las observaciones de la X del conjunto de testing set, y los valores predichos de y son comparados con los valores reales.

La división entre train y test se podría hacer a mano, pero Scikit-learn nos ofrece la función `train_test_split()`, que importaremos del módulo de `model_selection` de Scikit-Learn, el cual contiene herramientas para la selección y evaluación de modelos



¡Muchas gracias!