


Más práctica



Ejercicio




En 1948 en Framingham, un pequeño pueblo en Massachusetts, Estados Unidos, comenzó uno de los estudios médicos más famosos de la historia y que aún continúa vigente. El estudio, conocido también como Framingham Heart Study, consistió en la participación voluntaria de 3 generaciones de habitantes del pueblo, quienes fueron sometidos a estudios médicos regulares cada 3 a 5 años, generando un gran volumen de datos sobre la salud mental y física, especialmente de enfermedades cardiovasculares de todos los involucrados.

Los aportes de este estudio son numerosos, entre los cuales se destacan las relaciones entre el riesgo de tener una enfermedad cardíaca con varios aspectos de la vida cotidiana y del estado de salud general de las personas, tales como la presión sanguínea, los niveles de colesterol, el consumo de cigarrillos y factores psico-sociales. El término "factor de riesgo" fue acuñado como parte de los hallazgos de este estudio.



En esta práctica trabajaremos con un extracto del dataset resultante del estudio, en el que se cuenta con información médica de varios participantes, entre la que se encuentra el riesgo de que esa persona tenga una enfermedad coronaria durante los próximos 10 años. Nos propondremos entrenar un regresor logístico que permita clasificar y identificar los pacientes en riesgo de tener este tipo de enfermedad basándonos en sus datos clínicos



Ejercicio

El dataset cuenta con las siguientes variables:

age: Edad.

male: Género.

education: 1 = Some High School; 2 = High School or GED; 3 = Some College or Vocational School; 4 = college

currentSmoker: Si la persona fuma o no

cigsPerDay: la cantidad de cigarrillos que la persona fuma por día en promedio.

BPMeds: si la persona consume medicación para la presión sanguínea.

prevalentStroke: Si la persona tuvo un infarto anteriormente.

prevalentHyp: si la persona tiene hipertensión.

diabetes: si la persona tuvo diabetes.

totChol: nivel de colesterol total.

sysBP: presión sanguínea sistólica.


diaBP:: presión sanguínea diastólica.

BMI: índice de masa corporal.

heartRate: frecuencia cardíaca.

glucose: nivel de glucosa en sangre.

TenYearCHD: si la persona está en riesgo de tener una enfermedad coronaria dentro de los próximos 10 años.



Ejercicio

Importar el dataset y realizar un análisis exploratorio del mismo.

¿Cuántos registros hay?

¿Qué tipo de variable es cada una?

¿Hay valores faltantes?

¿Hay valores fuera del rango esperado?

¿En qué tipo de dato están almacenados?

¿Todas las variables son médicas o hay otra información en el dataset?

¿Hay correlación entre las variables?

¿En qué rango está cada una?

Cómo son las proporciones de las variables categóricas?

Realizar las visualizaciones adecuadas para responder estas preguntas

¡Muchas gracias!