

Introducción al Aprendizaje No Supervisado

Índice

- 01** ¿Qué es el Aprendizaje No Supervisado?
- 02** Clustering
- 03** Reducción de la dimensionalidad



01


¿Qué es el Aprendizaje No Supervisado?

El aprendizaje no
supervisado es como
explorar un mapa sin
un destino
predeterminado,
buscando entender la
topografía y los
puntos de interés por
nosotros mismos.



Aprendizaje No Supervisado

- En el aprendizaje no supervisado del campo del Machine Learning, nos adentramos en la exploración y descubrimiento de patrones ocultos en los datos **sin la ayuda de respuestas predefinidas o etiquetas específicas**.
- A diferencia del aprendizaje supervisado, donde se nos proporcionan ejemplos de entrada y las salidas correspondientes que queremos que el modelo aprenda, en el aprendizaje no supervisado nos enfrentamos a conjuntos de datos que no tienen etiquetas claras. *En lugar de eso, nuestro objetivo es encontrar patrones interesantes o agrupar los datos en categorías sin tener una guía explícita.*



Aprendizaje No Supervisado

Columns


Filas
Registros
Rows

Característica 1	Característica 2	Característica 3	...	Característica N

Características o Features


02 Clustering

Clustering



- El clustering es una técnica fundamental en el aprendizaje no supervisado, que se utiliza para organizar un conjunto de datos en grupos **basados en las similitudes entre las observaciones**. Este enfoque es especialmente útil cuando no se tiene información previa sobre las categorías a las que pertenecen los datos.
 - El objetivo del clustering es agrupar elementos similares en un mismo grupo y separar aquellos que son diferentes en distintos grupos.
- El proceso de clustering implica la identificación de patrones y estructuras ocultas dentro de los datos, permitiendo a los analistas descubrir relaciones y tendencias que no son claros a simple vista. Esta técnica se aplica en diversas áreas, como el análisis de mercado, la biología, la medicina, la detección de fraudes, y muchas más.
 - Por ejemplo, en el análisis de mercado, el clustering puede ayudar a segmentar a los clientes en diferentes grupos basados en su comportamiento de compra, permitiendo estrategias de marketing más personalizadas.

Algoritmos de clustering




- **K-Means:** Este es uno de los algoritmos más populares y ampliamente utilizados.
 - El algoritmo comienza seleccionando **K centroides aleatorios**, que representan el centro de cada grupo.
 - Luego, asigna **cada punto de datos al centroide más cercano** y recalculan los centroides como el promedio de los puntos asignados a cada grupo.
 - Este proceso se repite iterativamente hasta que los centroides ya no cambian significativamente, indicando que los grupos se han estabilizado.
- **Clustering jerárquico** (Hierarchical Clustering): Este método no requiere la especificación previa del número de grupos.
 - El proceso comienza considerando cada punto de datos como su propio grupo y, progresivamente, **fusiona los grupos más cercanos en un proceso jerárquico**.
 - El resultado es un árbol de grupos, llamado **dendrograma**, que muestra cómo se agrupan los datos en *diferentes niveles de similitud*.

03

Reducción de la dimensionalidad

Reducción de la dimensionalidad



- La reducción de dimensionalidad (dimensionality reduction) es una técnica empleada para **disminuir la cantidad de características o variables en un conjunto de datos**.
 - El objetivo principal es simplificar la representación de los datos mientras se conserva la mayor cantidad posible de información relevante.
- En muchos conjuntos de datos, especialmente aquellos con numerosas características, puede **haber redundancia o correlación entre las variables**, lo que complica el análisis y la visualización.
 - La reducción de dimensionalidad aborda este problema al *transformar los datos originales* en un **espacio de menor dimensión**.
 - En este espacio reducido, las nuevas variables (llamadas componentes principales o características latentes) **representan una combinación de las variables originales**.

Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales (PCA, por sus siglas en inglés) se utiliza para transformar un conjunto de datos posiblemente correlacionados en un conjunto de valores no correlacionados llamados componentes principales. Estos componentes principales son nuevas variables obtenidas a partir de combinaciones lineales de las variables originales del conjunto de datos.

Ventajas :

- **Reducción de Dimensionalidad:** Simplifica los datos, reduciendo el número de variables necesarias para describirlos.
- **Mejora del Rendimiento Computacional:** Disminuye el tiempo y los recursos necesarios para el procesamiento de datos.
- **Eliminación de Redundancia:** Al combinar variables correlacionadas, elimina la redundancia de información.

Limitaciones:

- **Linealidad:** Solo captura relaciones lineales entre variables, por lo que puede no ser efectivo para datos con relaciones no lineales.
- **Sensibilidad a la Escala:** Las variables deben estar en la misma escala, ya que PCA es sensible a las magnitudes de las variables.

Conclusiones

El aprendizaje no supervisado es una herramienta poderosa y versátil en el análisis de datos. Al permitir la identificación de patrones y estructuras ocultas sin la necesidad de datos etiquetados, ofrece una forma eficiente y efectiva de abordar problemas complejos y explorar datos de manera significativa.

