

Evaluación de Modelos



Cross Validation



La Validación cruzada o **cross validation** es un método que consiste en evaluar y probar el rendimiento de un modelo de machine learning, con el fin de encontrar un mejor modelo rápidamente. Esta técnica ayuda a la comprensión y aplicación de este modelado predictivo, siendo fácil y sencilla de aplicar.




La idea de la validación cruzada es simple: en lugar de usar diferentes sets para entrenamiento y validación **¡en la validación cruzada usaremos todos los datos!**

Validación Cruzada

La validación cruzada es una técnica utilizada para evaluar la capacidad predictiva de un modelo de machine learning, asegurando que este se generalice bien a datos no vistos. Este método implica dividir el dataset original en múltiples subconjuntos, conocidos como "folds". El proceso típico sigue estos pasos:

- **División del Dataset:** Se divide el dataset en k subconjuntos de aproximadamente el mismo tamaño. Este valor k se elige según la necesidad del análisis, siendo común el uso de $k = 5$ o $k = 10$
- **Entrenamiento y Evaluación:**
 - Para cada uno de los k subconjuntos, el modelo se entrena usando $k-1$ de esos subconjuntos como datos de entrenamiento.
 - El subconjunto restante se usa como conjunto de prueba.
 - Este proceso se repite k veces, cambiando el subconjunto de prueba en cada iteración.
- **Promedio de Resultados:** Se calculan los resultados de evaluación (como precisión, error, etc.) en cada una de las k iteraciones. Luego, se promedian estos resultados para obtener una medida final del desempeño del modelo.






Ventaja de la Validación Cruzada



Uso Eficiente de Datos: Maximiza el uso de los datos disponibles, ya que cada dato se utiliza tanto para entrenamiento como para prueba.




Evaluación Robusta: Proporciona una estimación más fiable del rendimiento del modelo, ya que se evalúa en múltiples particiones del dataset.



Tipos comunes de Validación Cruzada

- **k-Fold Cross Validation:** Como se describió, el dataset se divide en k partes.
- **Leave-One-Out Cross Validation (LOOCV):** Es un caso extremo donde k es igual al número de observaciones en el dataset. Cada iteración usa una sola observación como conjunto de prueba y el resto como conjunto de entrenamiento.
- **Stratified k-Fold Cross Validation:** Similar a k-Fold, pero se asegura de que cada fold mantenga la proporción original de clases en problemas de clasificación, proporcionando así una evaluación más equilibrada.





Hiperparámetros



Los hiperparámetros son las características externas de un modelo, **no se "aprenden"**, son valores que tiene que definirse cuando se implementa el modelo, antes de entrenarlo.

Un ejemplo es el valor k en el algoritmo K-means, o el nivel máximo de un árbol.



Los parámetros son las características internas de un modelo, son valores estimados a partir del entrenamiento con los datos.

Un ejemplo son los coeficientes de una regresión lineal.





Los parámetros son las características internas de un modelo, son valores estimados a partir del entrenamiento con los datos.

Un ejemplo son los coeficientes de una regresión lineal.

Hiperparámetros

No podemos saber a priori cuáles son los mejores valores de los hiperparámetros del modelo para resolver un problema determinado. Además, mientras una configuración específica de hiperparámetros puede generar una buena performance del modelo para un determinado dataset, en otro similar quizás no sea así.

Por lo tanto, **la optimización o ajuste de los hiperparámetros (hyperparameters tuning)**, es decir, la selección de un conjunto óptimo de valores para los hiperparámetros, es una parte esencial del machine learning. Sin embargo, los modelos pueden tener muchos hiperparámetros, y encontrar la mejor combinación se convierte en un problema de búsqueda de información.



Hiperparámetros



Vamos a analizar dos métodos de ajuste de hiperparámetros: Grid Search y Random Search. Ambos métodos siguen un proceso simple:


Para cada combinación de valores de los hiperparámetros:

- Aplican los valores sobre el conjunto de entrenamiento.
- Evalúan con validación cruzada.
- Registran el puntaje obtenido.

Al final de todas las búsquedas:

- Seleccionan la combinación con el puntaje más alto.
- Aplican la combinación seleccionada sobre el conjunto de entrenamiento.
- Predicen sobre el conjunto de prueba.







Hyperparameter Tuning



GridSearch busca la mejor combinación de hiperparámetros dentro de una grilla (grid) especificada previamente. La búsqueda es exhaustiva para cada valor de la grilla.



RandomSearch selecciona en forma aleatoria un subset de los hiperparámetros




Es importante tener en cuenta el costo a nivel de cómputo de evaluar todas las combinaciones de los valores de los hiperparámetros. Por lo tanto, en algunos casos vamos a tener que elegir una grilla reducida, o usar RandomSearch que selecciona un subset de combinaciones.

Grid Search

Pseudocode


```
Hyperparameter_One = [a, b, c]  
Hyperparameter_Two = [x, y, z]
```




Random Search

Pseudocode

```
Hyperparameter_One = random.num(range)  
Hyperparameter_Two = random.num(range)
```



Cómo se implementa



Para implementar una búsqueda de hiperparámetros en sklearn, debemos considerar los siguientes elementos:

1. **Un estimador:** Es decir, un modelo sobre el cual queremos trabajar.
2. **Un espacio de parámetros:** El rango de valores de los hiperparámetros sobre los cuales se realizará la búsqueda.
3. **Un método de búsqueda:** La estrategia utilizada para buscar entre los modelos candidatos (por ejemplo, RandomSearch o GridSearch).
4. **Un esquema de validación cruzada:** Seleccionando la cantidad de folds para dividir el dataset.
5. **La métrica de evaluación:** El criterio utilizado para elegir el mejor modelo.

¡Muchas gracias!