

Recursos del Curso: Introducción a Machine Learning

Bienvenidos al curso de Introducción a Machine Learning. En este documento encontrarás una recopilación de los recursos esenciales que utilizaremos a lo largo del curso. Estos recursos están organizados para facilitar su acceso y comprensión, y abarcan desde documentación oficial de las librerías y herramientas que utilizaremos, hasta los datasets específicos para cada módulo del curso.

Documentación Oficial

Lo siguiente es la documentación oficial de las herramientas y librerías que usaremos en el curso. Es importante familiarizarse con estos recursos ya que serán fundamentales para el desarrollo de los ejercicios y proyectos a lo largo del curso:

- **NumPy y Pandas:** Herramientas para la manipulación de datos.
 - [NumPy](#)
 - [Pandas](#)
- **Matplotlib y Seaborn:** Herramientas de visualización de datos.
 - [Matplotlib](#)
 - [Seaborn](#)
- **Scikit-learn:** Biblioteca para aprendizaje automático en Python.
 - [Documentación general](#)
 - [Train Test Split](#)
 - [Regresión Logística](#)
 - [Clasificador de Árboles de Decisión](#)
- **XGBoost:** Implementación optimizada de gradient boosting.
 - [Documentación de XGBoost](#)

Datasets Utilizados

A continuación, se presenta una lista de los datasets que utilizaremos en el curso, junto con una breve descripción y el módulo en el que se empleará cada uno. Todos estos datasets están disponibles en el siguiente repositorio de GitHub: [Recursos Descargables - Intro a Machine Learning](#).

Descripción del Dataset: [Default.csv](#)

Este dataset contiene información sobre clientes de un banco y se utiliza para predecir si un cliente caerá en default (incumplimiento de pago) en su tarjeta de crédito.

Este dataset es especialmente útil para practicar técnicas de clasificación en aprendizaje supervisado, como la regresión logística y los árboles de decisión.

El dataset **Default.csv** será utilizado en el **Módulo 3: Aprendizaje Supervisado**, donde aprenderemos a aplicar modelos de clasificación para predecir la probabilidad de default de un cliente en base a sus características demográficas y financieras.

Descripción del Dataset: [Movie_classification.csv](#)

Este dataset contiene información detallada sobre varias películas y se utiliza para construir modelos de clasificación que predigan el éxito de una película en términos de su recaudación en taquilla.

El dataset **Movie_classification.csv** será utilizado en el **Módulo 3: Aprendizaje Supervisado**, donde se aprenderá a aplicar modelos de clasificación para predecir la recaudación en taquilla de una película en función de diversos factores como el gasto en marketing, las calificaciones de actores y directores, y la disponibilidad en 3D, entre otros.

Descripción del Dataset: [HR_comma_sep.csv](#)

Este dataset contiene información sobre empleados de una empresa y se utiliza para predecir la rotación de empleados, es decir, si un empleado dejará la empresa.

El dataset **HR_comma_sep.csv** será utilizado en el **Módulo 3: Aprendizaje Supervisado**, donde se aprenderá a aplicar modelos de clasificación para predecir si un empleado dejará la empresa en función de diversas características como su nivel de satisfacción, evaluaciones, número de proyectos, y nivel de salario, entre otros.

Descripción del Dataset: [mall_customers.csv](#)

Este dataset contiene información sobre clientes de un centro comercial y se utiliza para realizar análisis de segmentación de clientes mediante técnicas de aprendizaje no supervisado, como el clustering.

El dataset **mall_customers.csv** será utilizado en el **Módulo 4: Aprendizaje No Supervisado**, donde se aprenderá a aplicar técnicas de clustering para segmentar a los clientes del centro comercial en diferentes grupos basados en características como la edad, el ingreso anual y la puntuación de gasto. Esto permitirá identificar patrones y comportamientos comunes entre los diferentes segmentos de clientes.

Descripción del Dataset: [abalone.csv](#)

Este dataset contiene información sobre abalones y se utiliza para predecir la edad de los abalones a partir de mediciones físicas.

El dataset **abalone.csv** será utilizado en el **Módulo 5: Evaluación de Modelos y Métricas de Rendimiento**, donde se aprenderá a aplicar diversas métricas para evaluar la precisión y efectividad de los modelos de regresión y clasificación. Este dataset es ideal

para practicar la predicción de una variable continua (edad del abulón) y la clasificación de abalones como adultos o no adultos.

Descripción del Dataset: [framingham.csv](#)

Este dataset contiene información de salud de los participantes del estudio Framingham Heart, un estudio epidemiológico a largo plazo sobre las enfermedades cardiovasculares.

El dataset **framingham.csv** será utilizado como ejercicio complementario en el Módulo 5: Evaluación de Modelos y Métricas de Rendimiento. En este ejercicio, los estudiantes aplicarán diversas métricas de evaluación para analizar la precisión y efectividad de los modelos predictivos de riesgo de enfermedad coronaria a 10 años, utilizando técnicas de regresión y clasificación.

Esperamos que estos recursos sean de gran ayuda para su aprendizaje y desarrollo en el curso. Les recomendamos revisar la documentación y familiarizarse con los datasets antes de cada módulo para maximizar su comprensión y aprovechamiento de los contenidos.

¡Éxito en su camino de aprendizaje en Machine Learning!