

Métricas para la Evaluación de Modelos de clasificación

Índice

- 01** Matriz de Confusión
- 02** Accuracy, Precisión, Recall, y F1-score.
- 03** ROC y AUC



01

Matriz de Confusión

Matriz de Confusión

		Valor predicho	
		Class = yes	Class = No
Valor real	Class = yes	TP	FN
	Class = No	FP	TN

- TP = Verdaderos positivos (True positives)
- FN = Falsos negativos (False Negative)
- FP = Falsos positivos (False positives)
- TN = Verdaderos negativos (True negatives)

02

Accuracy, Precisión,
Recall, y F1-score.

Accuracy

- Es la exactitud global del modelo corresponde a la proporción de datos que fueron correctamente clasificados, independiente de la categoría, por eso se considera la métrica de exactitud global.

		Valor predicho	
		Class = yes	Class = No
Valor real	Class = yes	TP	FN
	Class = No	FP	TN

$$Accuracy = \frac{TP + TN}{TP + TN + FN + FP}$$

Precisión

- La proporción de ejemplos correctamente clasificados como positivos (verdaderos positivos) en comparación con todos los ejemplos clasificados como positivos (verdaderos positivos y falsos positivos).

		Valor predicho	
		Class = yes	Class = No
Valor real	Class = yes	TP	FN
	Class = No	FP	TN

$$Precision = \frac{TP}{TP + FP}$$

Recall

- Es la proporción de ejemplos correctamente clasificados como positivos (verdaderos positivos) en comparación con todos los ejemplos que realmente son positivos (verdaderos positivos y falsos negativos). Esto refleja la capacidad del modelo para identificar correctamente los ejemplos positivos.

		Valor predicho	
		Class = yes	Class = No
Valor real	Class = yes	TP	FN
	Class = No	FP	TN

$$Recall = \frac{TP}{TP + FN}$$

F1 Score

- Es una métrica que combina la precisión y la sensibilidad en una sola medida. Es útil cuando se busca un equilibrio entre la precisión y la sensibilidad, ya que tiene en cuenta tanto los falsos positivos como los falsos negativos.

		Valor predicho	
		Class = yes	Class = No
Valor real	Class = yes	TP	FN
	Class = No	FP	TN


$$F1_{Score} = \frac{2 \cdot Recall \cdot Precision}{Recall + Precision}$$

03

ROC y AUC


Curva ROC (Receiver Operating Characteristic)

- La curva ROC (Receiver Operating Characteristic) es una representación gráfica utilizada para evaluar el rendimiento de un modelo de clasificación binaria. La curva ROC muestra la relación entre la tasa de verdaderos positivos (TPR, True Positive Rate) y la tasa de falsos positivos (FPR, False Positive Rate) a diferentes umbrales de clasificación.
 - La TPR, también conocida como sensibilidad o recall, se calcula como el número de verdaderos positivos dividido por la suma de verdaderos positivos y falsos negativos.
 - La FPR se calcula como el número de falsos positivos dividido por la suma de falsos positivos y verdaderos negativos.
- Para crear la curva ROC, se trazan los valores de TPR en el eje y (vertical) contra los valores de FPR en el eje x (horizontal) para cada posible umbral de clasificación.



AUC (Área Bajo la Curva)

- El AUC (Área Bajo la Curva) ROC es una métrica utilizada para evaluar el rendimiento de un modelo de clasificación binaria. Esta métrica representa el área delimitada por la curva ROC y el eje diagonal.
 - Cuanto mayor sea el AUC, mejor será el rendimiento del modelo. Un AUC de 1 indica un modelo perfecto, lo que significa que puede clasificar todas las instancias correctamente. Por otro lado, un AUC de 0.5 indica un modelo que no es mejor que una clasificación aleatoria.
- El AUC se calcula integrando el área bajo la curva ROC. En términos prácticos, esto se puede hacer utilizando métodos numéricos, como la regla del trapecio, o mediante funciones específicas en bibliotecas como scikit-learn en Python.



Conclusiones

Las métricas de evaluación de modelos son herramientas fundamentales en el desarrollo y la validación de modelos de machine learning. Estas métricas proporcionan una evaluación objetiva del rendimiento del modelo, lo que permite ajustar y mejorar nuestros modelos.

