

Árboles de Decisión

Índice

- 01** ¿Qué es un Árbol de Decisión?
- 02** CART
- 03** ¿Cómo decide un árbol donde ramificarse?




01

¿Qué es un Árbol de Decisión?

Árboles

Un árbol es una estructura jerárquica que se utiliza para representar relaciones entre diferentes elementos. Está compuesto por **nodos** y **aristas** (o ramas) que conectan estos nodos. Aquí están los elementos clave de un árbol:

- **Nodo Raíz:** Es el nodo superior del árbol, del cual parten todas las demás ramas. Solo hay uno en cada árbol.
- **Nodos Internos:** Son los nodos que tienen al menos un nodo hijo. Representan puntos de decisión o categorías intermedias.
- **Nodos Hojas:** Son los nodos que no tienen nodos hijos. Representan el final de una rama y suelen contener la información final o el resultado.
- **Ramas:** Conectan los nodos entre sí y representan la relación o el camino entre los nodos.




Árbol de decisión

Es un **modelo predictivo** que utiliza una estructura de árbol para tomar decisiones basadas en los *valores de los atributos de los datos*.

Aquí **cada nodo interno plantea una pregunta** sobre un atributo, **las ramas representan las posibles respuestas**, y **los nodos hojas representan la decisión final** o la predicción basada en el conjunto de respuestas anteriores.

Esta estructura permite desglosar un problema complejo en una serie de **preguntas binarias o categóricas** más simples, facilitando el proceso de toma de decisiones.



02

CART


CART (Classification and Regression Trees)

Es un algoritmo de machine learning que se utiliza tanto para problemas de **clasificación** como de **regresión**.

- **Inicio en la raíz:** El algoritmo comienza en la raíz del árbol y selecciona la mejor característica (**feature**) para dividir los datos en grupos (hijos).
- **Criterio de división:** Para problemas de **clasificación**, se usan el índice de **Gini** o la **Entropía** para medir la pureza de la división.
- **División recursiva:** La mejor división es la que maximiza la homogeneidad dentro de los grupos y la heterogeneidad entre ellos. Este proceso se repite recursivamente para cada nodo hijo, creando el árbol de decisiones.
- **Criterios de parada:** Para evitar que el árbol crezca indefinidamente, se utilizan criterios de parada como:
 - *Alcanzar una profundidad máxima del árbol.*
 - *Tener un número mínimo de observaciones en un nodo.*
 - *No lograr una mejora significativa en la medida de pureza.*



Hiperparámetros

- ¿Hasta qué nivel puede crecer el árbol?
- ¿Cuántos atributos debemos considerar en un árbol?
- ¿A partir de cuántas observaciones podemos seguir dividiendo?
- ¿Con cuántas observaciones dejamos de subdividir?




Hiperparámetros

- Se divide la población o muestra en conjuntos homogéneos basados en la variable de entrada más significativa
- La construcción del árbol sigue un enfoque de división binaria recursiva (top-down greedy approach). Greedy -> analiza la mejor variable para ramificación sólo en el proceso de división actual.




Ventajas

- Fácil de entender
- Útil en exploración de datos: identificar importancia de variables a partir de cientos de variables.
- Menos limpieza de datos: outliers y valores faltantes no influyen el modelo (A un cierto grado)
- El tipo de datos no es una restricción
- Es un método no paramétrico (i.e., no hay suposición acerca del espacio de distribución y la estructura del clasificador)



Desventajas

- Sobreajuste
- Pérdida de información al categorizar variables continuas
- Precisión: métodos como SVM y clasificadores tipo ensamblador a menudo tienen tasas de error 30% más bajas que CART (Classification and Regression Trees)
- Inestabilidad: un pequeño cambio en los datos puede modificar ampliamente la estructura del árbol. Por lo tanto la interpretación no es tan directa como parece.




03

¿Cómo decide un árbol
donde ramificarse?

¿Cómo decide un árbol donde ramificarse?

- La decisión de hacer divisiones estratégicas afecta altamente la precisión del árbol.
- Los criterios de decisión son diferentes para árboles de clasificación y regresión.
- Existen varios algoritmos para decidir la ramificación.
- La creación de subnodos incrementa la homogeneidad de los subnodos resultantes. Es decir, la pureza del nodo se incrementa respecto a la variable objetivo.
- Se prueba la división con todas las variables y se escoge la que produce subnodos más homogéneos.



Algunos algoritmos más comunes para la selección: **Índice Gini**, **Entropía**, Chi Cuadrado, Ganancia de la información y Reducción en la varianza

Métricas de división para clasificación

GINI:

El índice de Gini se encuentra en el rango entre 0 y 1 y suele utilizarse por defecto el índice de Gini para medir la impureza de una división.

- **D**: Conjunto de datos sobre el cual queremos medir la pureza.
- **k**: Número de clases.
- **p_i**: Proporción de ejemplos en el nodo actual que pertenecen a la clase i.

La pureza mide qué tan homogéneos son los datos en cada nodo, y se calcula usando estas proporciones.

A mayor valor de índice Gini, mayor la homogeneidad

$$GINI(D) = 1 - \sum_{i=1}^k p_i^2$$

Métricas de división para clasificación


Entropía:

- Un nodo menos impuro requiere menos información para ser descrito mientras un nodo más impuro necesita más información.
- La teoría de la información es una medida para definir este grado de desorganización en un sistema denominado como Entropía.
- Muestra completamente homogénea = entropía 0.
- Muestra igualmente dividida (50% – 50%) = entropía 1.

$$ENTROPIA(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

Conclusiones

Los árboles de decisión para clasificación son modelos poderosos que dividen los datos en segmentos más simples basados en características, buscando maximizar la pureza en cada división. Utilizan criterios como el índice de **Gini** o la **Entropía** para medir la homogeneidad de los grupos resultantes. Son fáciles de interpretar y pueden manejar datos numéricos y categóricos.



¡Muchas gracias!