


Introducción al Clustering




01

Clustering

Clustering

Es el proceso de organizar los objetos en grupos cuyos miembros son similares y los grupos distintos entre sí. Llamamos cluster a la colección de datos similares entre ellos.




¿Cuál es la diferencia entre Clustering y Clasificación ?

En la clasificación, estamos agrupando los datos de acuerdo con un conjunto de grupos predefinidos por la clase. (Supervisado). En clustering agrupamos los datos con características similares. En otras palabras, tenemos que descubrir las propias clases. (No Supervisado)


Clustering

- Los datos no están etiquetados.
- Agrupa puntos que están "cerca" entre sí.
- Identificar estructuras o patrones en los datos.
- Aprendizaje No Supervisado.




Classification

- Puntos de datos etiquetados
- Quiere una "regla" que asigne etiquetas a nuevos puntos.
- Aprendizaje Supervisado



Aplicaciones




- **Retail:** Se utiliza para agrupar clientes según su comportamiento de compra, preferencias de productos, etc.
- **Salud:** Se puede aplicar clustering para agrupar perfiles de pacientes según características clínicas, historial médico, etc. También se puede utilizar para agrupar genes o proteínas según sus funciones, lo que puede ayudar en la identificación de patrones genéticos.
- **Banca:** Se puede hacer análisis de transacciones para detectar patrones de comportamiento anómalos.

Como el objetivo del clustering es encontrar grupos de datos similares entre sí, los resultados dependen de cómo medimos dicha similaridad.

En clustering, la distancia es la medida más común. La usamos en los algoritmos K-means y Clustering Jerárquico.

Otra forma de agrupar es determinando cómo se distribuyen las observaciones en el espacio de dimensiones. Lo llamamos estimación de la densidad.




Clustering con distancia

Clustering con estimación de densidad

En los algoritmos basados en distancia, se deben agrupar las observaciones tales que:

- Las distancias internas deberían **ser pequeñas**. Dentro del cluster.
- Las distancias externas deberían **ser grandes**. Entre los clusters.



02

¿Qué es K-Means?


K-means

K-means es uno de los algoritmos más conocidos para identificar clusters, por su simplicidad y eficiencia.

- **Simplicidad:** fácil de entender y de implementar.
- **Eficiencia:** la complejidad en tiempo de cómputo es $O(tkn)$, donde **n** es el tamaño de la muestra, **k** el número de clusters y **t** es el número de iteraciones.
 - *Como k y t son pequeños valores, se considera un algoritmo lineal.*

El número de clusters es fijado a priori y los clusters son disjuntos.

El criterio para agrupar los datos es por su cercanía a ciertos puntos en el espacio llamados **centroides**




K-means



Este metodo, como los de particiones en general, asume que el numero final de clusters (**k**) es conocido.

El procedimiento conlleva los siguientes pasos:

1. Determinar los centroides iniciales o semillas de los k grupos.
2. Asignar cada observacion al centroide más cercano segun la distancia.
3. Con las observaciones clasificadas se recalculan los centroides de los k grupos. Si las distancias entre los nuevos y viejos centroides es mayor que un criterio de convergencia establecido, *se vuelve al paso 2*.
4. El proceso termina cuando se cumple el criterio de convergencia. Además, se fija un número de iteraciones que no debe superarse.




K-means - Ejemplo - Parte 1




Paso 1

Se generan centroides aleatorios, en este caso 4



Paso 2



Se asigna cada observación al centroide más cercano según la distancia



Paso 3


Con las observaciones clasificadas se recalculan los centroides de los k grupos.

K-means - Ejemplo - Parte 2



Paso 2



Se asigna cada observación al centroide más cercano según la distancia



Paso 3


Con las observaciones clasificadas se recalculan los centroides de los k grupos.

K-means - Ejemplo - Parte 3



Paso 2

Se asignar cada observacion al centroe más cercano segun la distancia



Paso 3

Con las observaciones clasificadas se recalculan los centroides de los k grupos.

	X1	X2
Centro_0	0.929175	4.290231
Centro_1	2.019427	0.874748
Centro_2	-1.498074	2.901649
Centro_3	-1.272839	7.846515

Paso 4

El criterio de convergencia se cumplió, termina el proceso y se muestran los 4 centroides finales.


K-means

El algoritmo tiene como objetivo minimizar la función objetivo:

$$J = \sum_{j=1}^k \sum_{\vec{x} \in S_j} ||\vec{x} - \vec{c}_j||^2$$

Donde $\vec{c}_j$ es el centroide del cluster S_j

- Se busca minimizar la función J que es la suma de las distancias al cuadrado de los puntos al centroide de su cluster.
- K-means no necesariamente selecciona el mínimo de la función objetivo, ya que es sensible a la selección inicial de los centroides.




Cómo evaluamos si el valor K cantidad de clusters es el óptimo?

Regla del codo (inercia):

- A medida que aumenta el número de clusters, la suma de distancias cuadráticas se achica.
- **Evidentemente, si k fuera igual a n, habría un centroide para cada punto y las distancias serían todas iguales a cero.**
- Pero podemos aplicar un criterio para elegir el k mirando este gráfico. Lo llamamos la regla del codo (Elbow method).

Se elige el k a partir del cual la curva se aplana, "**donde se encuentra el codo**".



Cómo evaluamos si el valor K cantidad de clusters es el óptimo?

Silhouette score:

- El coeficiente Silhouette mide cuán cercano es un punto al resto de los que están en su mismo cluster, en relación a cuán cercano es a los puntos del cluster más próximo.
- Es decir que para cada punto i , se tiene un coeficiente s_i

$$s_i = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

en donde $a(i)$ es la **distancia promedio a los otros puntos del mismo cluster** y $b(i)$ es la **distancia promedio a todos los puntos del cluster vecino más cercano**.

De esta manera

$$-1 \leq s_i \leq 1$$

Cómo evaluamos si el valor K cantidad de clusters es el óptimo?

Silhouette score:

$$-1 \leq s_i \leq 1$$


- Si
 - s es cercano a 1, significa que el punto i está correctamente etiquetado
 - s cercano a cero indica que estaría igual de bien (o mal) etiquetarlo con el cluster vecino más cercano
 - s cercano a -1 significa que el punto i está mal etiquetado y pertenece al cluster vecino.

Para obtener un score del clustering promediamos los coeficientes:

$$S(C) = \frac{1}{k} \sum_{j=1}^k \bar{s}_j$$

en donde $\bar{s}_j$ es el coeficiente promedio de todos los puntos dentro del cluster j-ésimo.

Cómo evaluamos si el valor K cantidad de clusters es el óptimo?



Conclusiones

El clustering es una herramienta poderosa que nos permite descubrir patrones ocultos y estructuras subyacentes en nuestros conjuntos de datos. Hemos explorado K-means como técnica y métricas de evaluación que nos ayudan a entender la calidad y coherencia de los agrupamientos obtenidos.

