

Desafío Profesional Data Science

Te damos la bienvenida

El Desafío Profesional se plantea como una forma integral de evaluación dentro de la Certificación en Data Science. Es una parte crucial de la formación en Digital House y un requisito indispensable para obtener la certificación.

Este documento tiene como objetivo presentar algunos pilares fundamentales: el desafío propuesto, lo que esperamos de un científico de datos como tú, y las formas de evaluación que implementaremos para confirmar que has completado con éxito la especialización. ¿Listos?



Índice

- 01 ¿Qué es el desafío profesional?
- 02 ¿Qué buscamos?
- 03 Etapas
- 04 Evaluación



01


¿Qué es el desafío profesional?

¿Qué es el desafío profesional?

El Desafío Profesional es una aplicación práctica de los conceptos teóricos estudiados hasta el momento y tiene como objetivo el desarrollo de un proyecto integral de Ciencia de Datos. Funciona como una estrategia didáctica que consiste en la realización de un conjunto de actividades interrelacionadas con un inicio, un desarrollo y un final.

La metodología que utilizamos en Digital House de “aprender haciendo” favorece la articulación de conocimientos teóricos y prácticos, además de acercar a los estudiantes a la realidad del mercado profesional en el campo del Data Scientist.





Beneficios

01

Permite aplicar las herramientas aprendidas en los módulos realizados.


02

Nos desafía a llevar las ideas a la práctica.

¿Cómo funciona?

En esta **Certificación Data Science**, el desafío está orientado a la creación de un proyecto integral que abarca desde el **análisis y limpieza de datos** hasta la aplicación de modelos de **Machine Learning y Redes Neuronales** para resolver problemas complejos de negocio.


Te **sugerimos** comenzar este desafío después de haber completado los cursos de la certificación, ya que involucra la aplicación de todos los conocimientos adquiridos en los módulos anteriores, con un enfoque especial en la construcción de modelos predictivos, interpretación de resultados y comparación de métodos.



¿Cómo funciona?

El desafío se divide en cuatro etapas principales:


- **Etapas 1 y 2:** Revisión y aplicación de la exploración y limpieza de datos realizada en el *Desafío de Data Analyst*.
- **Etapas 3:** Creación y evaluación de modelos de *Machine Learning* tradicionales.
- **Etapas 4:** Implementación de *Redes Neuronales*, *Fine Tuning* y comparación con los modelos tradicionales.



¿De qué se trata el desafío?

El objetivo del proyecto es **realizar un análisis integral de un conjunto de datos de un caso de negocio real**, aplicando técnicas avanzadas de **Data Science**. El estudiante deberá **explorar, limpiar, modelar y evaluar datos**, utilizando modelos de **Machine Learning** y **Redes Neuronales** para generar insights y recomendaciones.

Se trabajará con datos reales para identificar patrones, construir modelos predictivos y validar resultados. El desafío implica documentar todo el proceso analítico y asegurar un registro detallado de las transformaciones y evaluaciones realizadas.



02

¿Qué buscamos?

¿Qué buscamos?



- **Carga y exploración de datos:** Importación y exploración inicial de los datasets proporcionados.
- **Limpieza y transformación de datos:** Procesos de limpieza de datos para asegurar su integridad y consistencia, incluyendo la gestión de valores faltantes y la normalización de datos.
- **Análisis exploratorio de datos (EDA):** Realización de un análisis exploratorio para identificar patrones, tendencias y anomalías en los datos.

¿Qué buscamos?



- **Visualización:** Crear gráficos claros usando herramientas como Matplotlib, Seaborn, Plotly, Dash, o Power BI.
- **Modelado:** Desarrollar y evaluar modelos de Machine Learning y Redes Neuronales para resolver el caso de negocio.
- **Presentación de insights:** Formular conclusiones y recomendaciones basadas en el análisis y comunicarlo mediante un storytelling efectivo.

03

Etapas

Etapas

Etapas

Exploración Visual de los Datos

En esta primera etapa, los estudiantes aplicarán los conocimientos adquiridos en los módulos de *Introducción a Python*, *Programación en Python*, *Matemática para IA* y *Visualización de Datos con Python*. El objetivo es realizar una exploración visual de los datos utilizando técnicas de análisis exploratorio de datos (EDA). Los estudiantes crearán visualizaciones iniciales que les permitan identificar patrones, tendencias, y posibles anomalías en el dataset.



Si ya completaste el Desafío Profesional de Data Analyst, **¡esta etapa ya la tienes realizada!**




Etapa 2

Limpieza y Transformación de Datos

En la segunda etapa, los estudiantes pondrán en práctica los conocimientos de los módulos de **Bases de Datos en MySQL** y el módulo de **Exploración y Limpieza de Datos**. Aquí, el enfoque estará en la limpieza y transformación de los datos para asegurar que estén en condiciones óptimas para el análisis posterior. Se espera que los estudiantes manejen valores faltantes, normalicen variables, y apliquen técnicas de integración de datos.




Si ya completaste el Desafío Profesional de Data Analyst, **¡esta etapa ya la tienes realizada!**



Etapa 3

Modelado con Machine Learning


Esta etapa se centra en los cursos de **Introducción a Machine Learning**, **Modelado avanzado en Machine Learning**, y **Aprendizaje no supervisado**. Los estudiantes desarrollarán modelos supervisados y no supervisados utilizando los datos limpios. Aplicarán técnicas de modelado predictivo como regresión, clasificación y clustering para resolver el problema planteado, evaluando los resultados con métricas adecuadas.



Etapa 4


Implementación de Redes Neuronales

En esta etapa y última, se trabajará con los cursos de **Redes neuronales**, **Fundamentos de Deep Learning**, y **Gestión de proyectos de IA**. Los estudiantes construirán redes neuronales para abordar el mismo problema, utilizando frameworks como TensorFlow o PyTorch. Compararán el rendimiento de las redes neuronales con los modelos tradicionales y presentarán un análisis final con las conclusiones y aprendizajes obtenidos



04

Evaluación



La evaluación del Desafío Profesional tiene como objetivo asegurar que los estudiantes apliquen de manera efectiva los conocimientos adquiridos a lo largo del curso en un proyecto integral y desafiante de Data Science. Se considerarán diversos aspectos clave para medir la **profundidad del análisis**, la **calidad de los modelos implementados**, y la **efectividad de las soluciones propuestas** para resolver el problema de negocio.

Profundidad del Análisis Exploratorio de Datos

- **Evaluación:** Se evaluará si el análisis exploratorio cubre todas las variables relevantes para la creación de modelos predictivos.
- **Criterios:** Identificación de patrones, tendencias, y posibles anomalías que puedan influir en los modelos.
- **Técnicas:** Verificación del uso de técnicas estadísticas avanzadas, como la identificación de correlaciones significativas y distribuciones.
- **Visualizaciones:** Uso efectivo de herramientas de visualización para comunicar insights, incluyendo histogramas, heatmaps, y matrices de correlación.

Calidad y Limpieza de los Datos Procesados

- **Evaluación:** Se evaluará la detección y tratamiento de datos faltantes, outliers y la preparación adecuada de los datos para el modelado.
- **Transformaciones:** Verificación de la correcta aplicación de transformaciones y normalizaciones necesarias para el modelado, asegurando que los datos estén listos para Machine Learning.
- **Documentación:** Asegurarse de que el proceso de limpieza esté bien documentado y sea reproducible para garantizar la trazabilidad.

Desarrollo y Evaluación de Modelos

- **Selección de Modelos:** Evaluación de la elección adecuada de algoritmos de Machine Learning y Redes Neuronales según el problema planteado.
- **Entrenamiento y Validación:** Verificación del uso de técnicas de validación cruzada y ajuste de hiperparámetros para obtener los mejores resultados.
- **Métricas:** Análisis del uso de métricas de evaluación como precisión, recall, F1-score, AUC-ROC, MSE, entre otras, para la evaluación de los modelos.
- **Comparación de Modelos:** Evaluación de cómo se comparan los modelos tradicionales con las Redes Neuronales implementadas en la Etapa 4.

Uso de Herramientas y Librerías Avanzadas

- **Python y Librerías:** Evaluación del uso eficiente de Python, y librerías de Machine Learning (Scikit-Learn, TensorFlow, PyTorch, etc.).
- **Visualización Avanzada:** Uso de herramientas como Matplotlib, Seaborn, Plotly o Dash para crear visualizaciones que complementen el análisis de modelos.
- **Documentación de Modelos:** Revisión de la claridad y estructura del código y la implementación de los modelos.
- **Buenas Prácticas:** Evaluación de la legibilidad, organización y buenas prácticas de programación.

Calidad y Claridad de la Presentación de Resultados

- **Visualización de Resultados:** Evaluación de cómo los resultados de los modelos se presentan de manera clara y comprensible.
- **Comparación de Modelos:** Capacidad para visualizar y explicar las diferencias entre los modelos tradicionales y Redes Neuronales.
- **Storytelling:** Capacidad de contar una historia con los datos y modelos, comunicando insights de manera efectiva y persuasiva.

Coherencia y Justificación de las Conclusiones

- **Fundamentación:** Evaluación de si las conclusiones y recomendaciones están basadas en el análisis de datos y en los resultados de los modelos.
- **Storytelling Técnico:** Comprobación de la capacidad del estudiante para comunicar los resultados técnicos de manera clara y coherente.
- **Justificación:** Verificación de que todas las decisiones tomadas en la elección y ajuste de los modelos estén bien justificadas y documentadas.

Performance y Escalabilidad

- **Mantenimiento y Adaptabilidad:** Evaluación de la facilidad de mantenimiento y adaptación del código y modelos para futuros cambios o actualizaciones.
- **Documentación y Código:** Revisión de la documentación que soporte futuras modificaciones y reutilización del código.
- **Rendimiento de Modelos:** Evaluación de la eficiencia y escalabilidad de los modelos desarrollados, asegurando que funcionen bien con datos adicionales o en un entorno de producción.

¡Muchas gracias!