

Introducción a Boosting

01

Boosting



La principal diferencia con las técnicas de Bagging, es que en ellas se entrenaban los modelos independientemente para luego generar un meta-modelo. En el caso de Boosting, se entrenan los modelos de manera secuencial donde cada modelo aprende de los errores del modelo predecesor.





Gradient Boost

Gradient Boosting es un método de aprendizaje **lento** donde los sucesivos modelos de árboles de decisión son entrenados para predecir los **residuales** del árbol antecesor.

Hiperparámetro de Learning Rate (η):

- **Descripción:**

- El Learning Rate (η) es un escalar entre 0 y 1 ($0 < \eta < 1$) que multiplica los residuales para asegurar la **convergencia**.

- **Recomendación:**


- A medida que se reduce el valor de η , es recomendable **aumentar** el número de estimadores (N).


La predicción del meta-modelo estará conformada de la siguiente manera:

$$\hat{y}_{\text{pred}} = y_1 + \eta r_1 + \eta r_2 + \dots + \eta r_N$$

Implementación en sklearn:

- **Regresión:** GradientBoostingRegressor
- **Clasificación:** GradientBoostingClassifier





ADA Boost

ADA proviene de **Adaptative Boosting**, que hace referencia a su capacidad de **adaptar la importancia** de los predictores, asignando mayor peso a aquellos sobre los que se comete más error.

Comparación con Random Forest

- **Poda de Árboles:**
 - En **Random Forest**, los árboles no se podan.
 - En **ADA Boost**, se utilizan árboles de 1 nodo raíz y 2 nodos hojas, conocidos como **stump**.
- **Peso en la Predicción:**
 - En **Random Forest**, cada árbol tiene igual voto sobre la predicción final.
 - En **ADA Boost**, los votos de los stumps pueden tener distintos pesos.

Funcionamiento de ADA Boosting


Creación del Primer Stump


1 Selección del Feature:

- Se elige el feature que genera la menor **entropía** o **índice de Gini** y se crea el primer **stump** con dicho feature.

2 Cálculo de la Importancia del Árbol:

- Se calcula la importancia del árbol dependiendo de la cantidad de error cometido
- El error se calcula sumando los pesos de todas las observaciones mal clasificadas (valor entre 0 y 1).
 - **Error = 1:** No clasificó nada correctamente, tendrá muy poco voto en la predicción final.
 - **Error = 0:** Clasificó todo perfectamente, tendrá mayor voto en la predicción final.





Funcionamiento de ADA Boosting

3 Ajuste de Pesos:

- Para que el siguiente stump pueda aprender del precursor, se ajustan los pesos de cada observación del dataset.
- La suma total de los pesos siempre es 1.

Creación de los Siguietes Stumps

4 Selección de Partición:

- El segundo stump utiliza el **weighted Gini index** para seleccionar la mejor partición.

5 Repetición del Proceso:

- Se calcula el error total de este stump para asignarle el peso a su voto.
- Se vuelven a recalcular los pesos de cada observación para entrenar al siguiente stump.


Predicción del Meta-modelo en ADA Boosting


Clasificación

- **Método:**
 - La predicción se realiza mediante **voto con pesos**.
- **Implementación en sklearn:**
 - `AdaBoostClassifier`

Regresión

- **Método:**
 - La predicción se realiza mediante **promedio ponderado**.
- **Implementación en sklearn:**
 - `AdaBoostRegressor`






XG Boost

XGBoost (Extreme Gradient Boosting) es una técnica avanzada de boosting que calcula los gradientes de segundo orden, es decir, las segundas derivadas parciales de la función de pérdida.

Características Clave

- **Gradientes de Segundo Orden:**
 - Proporcionan más información sobre la dirección de los gradientes y cómo llegar al mínimo de la función de pérdida.
 - Mientras que el gradient boosting usa la función de pérdida del modelo base (por ejemplo, árbol de decisión) como un proxy para minimizar el error del modelo general, **XGBoost** utiliza la derivada de segundo orden como una aproximación.
- **Ventajas del Entrenamiento:**
 - **Velocidad:** El entrenamiento es muy rápido.
 - **Paralelización:** Se puede paralelizar y distribuir entre clústeres.



¡Muchas gracias!