

Implementación de Random Forest

01

Bagging



El problema inherente de los árboles de decisión es la alta varianza que poseen. Para comprender esto pensemos en el siguiente ejercicio: **supongamos que ya hemos construido un árbol de decisión sobre un dataset determinado**. Ahora si dividimos dicho dataset en 2 partes y luego generamos un árbol de decisión para cada una de las partes, lo más probable es que obtengamos 2 nuevos árboles muy disímiles entre sí e incluso muy diferentes al árbol que generamos para el dataset original. También mencionamos que los métodos de ensamble ayudan a reducir el error por varianza aumentando así el accuracy final del modelo.







¿Qué es
bagging?

El nombre **Bagging** proviene de: **Bootstrap Aggregation**, veamos entonces primero qué significa **Bootstrap**.

El método Bootstrap consiste en generar, a partir de un dataset original, N nuevos datasets con la misma cantidad de variables independientes, tomando muestras con repetición.

Muestras con Repetición: Al aplicar la técnica de Bootstrap, es posible tener observaciones repetidas dentro de los nuevos datasets.





Funcionamiento del Método de Ensamble (Bagging)

- **Generación de Modelos:**

- El método de ensamble genera **N modelos distintos** al entrenar **N árboles de decisión** con **N datasets "distintos"**.
- Estos datasets son creados a partir de la técnica de **bootstrapping**.

Predicción Final del Meta-modelo

- **Clasificación:**


- La predicción agregada se consigue mediante **votación por mayoría**.
- La clase indicada por la mayoría de los modelos será la utilizada.

- **Regresión:**

- La predicción agregada utiliza el **promedio** de las regresiones de los modelos.

$$S^2$$

$$\frac{S^2}{N}$$




Características del Bagging

- **Poda de Árboles:**

- Al realizar Bagging, **no se realiza poda** de los N árboles de decisión utilizados en el ensamble.
- Esto es para que tengan el menor **error de bias** posible, incluso si tienen un gran **error de varianza**.

- **Reducción del Error de Varianza:**

- Mediante la agregación, el meta-modelo reduce el error de varianza de manera tal que:
 - Si la varianza de los modelos de árbol de decisión es s^2
 - Entonces se espera que el modelo de Bagging alcance un error de varianza de $\frac{s^2}{N}$





Final Model

02


Random Forest


Un Random Forest (Bosque Aleatorio) es un algoritmo de aprendizaje supervisado que se utiliza tanto para clasificación como para regresión. Fue desarrollado por Leo Breiman y Adele Cutler. **El algoritmo se basa en la construcción de múltiples árboles de decisión** durante el entrenamiento y la agregación de sus predicciones para mejorar la precisión y controlar el sobreajuste.



Construcción del Bosque:

1. Se generan múltiples subconjuntos de datos a partir del conjunto de datos original mediante muestreo con reemplazo (bootstrap sampling).
2. Para cada subconjunto, se construye un árbol de decisión de manera independiente.
3. Durante la construcción de cada árbol, en cada nodo de decisión, se selecciona aleatoriamente un subconjunto de características para determinar la mejor división.
4. Predicción: Para una tarea de clasificación, se realiza una votación mayoritaria entre todos los árboles: la clase más común entre las predicciones de todos los árboles es la predicción final.
5. Para una tarea de regresión, se toma el promedio de las predicciones de todos los árboles.





Bagging es un caso particular de **Random Forest** donde el tamaño de las muestra de los predictores **M** coincide con el tamaño de la población de los mismos **P**.

Empíricamente se observó que los siguientes valores de **M** suelen lograr descorrelacionar los modelos:

- **Para Regresiones:** $M = P/3$
- **Para Clasificaciones:** $M = \sqrt{P}$ No obstante si los predictores están altamente correlacionados entonces se pueden utilizar valores más pequeños de M .

Finalmente, la predicción del meta-modelo funciona exactamente igual que en el caso de Bagging.

¡Muchas gracias!