


Regularización: Ridge y Lasso



Función de pérdida de una regresión lineal:

$$CF = \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

Las técnicas de regularización agregan una "penalidad" a esta función de costo:

$$CF = \sum_{i=1}^N (\hat{y}_i - y_i)^2 + \alpha \cdot \vec{\theta}$$

$\vec{\theta}$ (theta) es el vector que corresponde a los parámetros del modelo (en una regresión lineal, los betas) y alpha es un parámetro que “regula” la fuerza de la penalización: cuanto más grande es, mayor es la penalización.

Normas **L1 y L2**



Norma L0

La cantidad de elementos distintos de cero en el vector.



Norma L1

La suma de los valores absolutos de los elementos del vector.

$$\|\beta\|_1 = \sum_i |x_i|$$



Norma L2

La raíz cuadrada de la suma de cuadrados de los elementos del vector.

$$\|\beta\|_2 = \sqrt{\sum_i x_i^2}$$

Normalización

Normalización L1

- La idea de esta normalización es que la suma del valor absoluto sea unitaria:

$$\sum_{j=1}^p \|x_{ij}\| = 1 \forall i = 1..n$$


Normalización L2

- La idea de esta normalización es que la suma del valor absoluto al cuadrado sea unitaria:

$$\sum_{j=1}^p \|x_{ij}\|^2 = 1 \forall i = 1..n$$

01

Regresión Ridge



Regresión Ridge

$$\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p \beta_j^2 = RSS + \lambda \sum_{j=1}^p \beta_j^2$$

Existe un término de penalización, que es menor cuando los betas se acercan a cero, por lo tanto tiene el efecto de achicar los mismos hacia cero (tanto si son negativos como positivos)

El hiperparámetro λ maneja la ponderación de cada término.

¿Cuál es el mejor valor para lambda? ¿Cómo elegíamos el valor óptimo de un hiperparámetro?

Como siempre, lo hacemos mediante **CROSS VALIDATION**



Regresión Ridge

En Regresión Ridge tanto la estimación de los coeficientes como la predicción son sensibles a la escala.

Si una variable se encuentra en una escala que le da un valor absoluto mayor, esto va a afectar el cálculo de la suma de cuadrados del vector de coeficientes.

Por esta razón es importante estandarizar (dividir por el desvío estándar) todos los regresores antes de ejecutar una regresión Ridge. Así ya no están en unidades físicas sino en unidades de su propio desvío estándar.

$$\tilde{x}_{ij} = \frac{x_{ij}}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}}$$

02

Regresión Lasso



Regresión Lasso

La regresión Ridge tiene una clara desventaja: incluye todos los predictores p en el modelo final, a diferencia de aquellos modelos que eligen un subconjunto de predictores.

La regresión Lasso es una alternativa a Ridge, que corrige esta desventaja. Los coeficientes $\beta_{L\lambda}$ minimizan el número de predictores

Lasso utiliza la norma **L1** en la penalización a diferencia de **ridge** que usa la norma **L2**.

$$\mathcal{L}(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j|$$



Regresión Lasso

Como en la regresión Ridge, Lasso "achica" los coeficiente estimados.

En el caso de Lasso, la regularización L1 fuerza los coeficientes a valer exactamente cero, en el caso de que λ sea lo suficientemente grande.


Por lo tanto, la regularización de Lasso hace selección de variables

Decimos que Lasso genera modelos dispersos, es decir modelos con una selección de variables

Al igual que en Ridge, la elección de un buen valor λ es crítico en Lasso; nuevamente cross-validation es el método para su elección

03

Elastic Net



Elastic Net

$$\lambda_1 \cdot \|\beta\|_1 + \lambda_2 \cdot \|\beta\|_2^2 = \lambda \cdot (\|\beta\|_1 + \alpha \|\beta\|_2^2)$$

ElasticNet combina linealmente lo mejor de ambos mundos.

El parámetro λ regula la complejidad del modelo. El parámetro α regula la importancia relativa de Lasso vs. Ridge.

Es posible obtener soluciones parsimoniosas y bien condicionadas.

No free lunch!: ahora hay que calibrar dos hiperparámetros.

¡Muchas gracias!