


Principios de Regresión Lineal

01

¿Qué es una Regresión Lineal?



La regresión lineal simple intenta predecir una respuesta cuantitativa Y en base a una única variable predictora X . Asume que hay aproximadamente una relación lineal entre X e Y . Matemáticamente:

$$Y = \beta_0 + \beta_1 \cdot X$$

Podemos leer esta expresión como "se modela aproximadamente como".

β_0 y β_1 son dos constantes que representan el intercepto y la pendiente en el modelo lineal.

β_0 y β_1 son conocidos como los parámetros del modelo.





Regresión Lineal

Entrenar el modelo equivale a calcular sus parámetros, que para la regresión lineal son los estimadores β_0 y β_1 de los coeficientes de la regresión.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$

donde $\hat{y}$ indica una predicción de Y basada en un valor particular x . Aquí usamos un símbolo $\hat{}$ para denotar el valor estimado para un parámetro o coeficiente desconocido, o para denotar el valor predicho de la respuesta.



Estimación de los coeficientes

Residuo o error de predicción: $e_i = y_i - \hat{y}_i$

Suma residual de cuadrados (RSS):


$$RSS = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 \cdot x_i)^2$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\bar{y} \equiv \frac{1}{n} \sum_{i=1}^n y_i$$

$$\bar{x} \equiv \frac{1}{n} \sum_{i=1}^n x_i$$



02

Evaluación del Modelo

Error Absoluto Medio (Mean Absolute Error, MAE):

El Error Absoluto Medio (Mean Absolute Error, MAE) es una medida utilizada para evaluar la precisión de un modelo de regresión. Proporciona una idea clara de cuánto difieren, en promedio, las predicciones de los valores reales observados. El MAE es fácil de interpretar y comparar entre diferentes modelos.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Error Cuadrático Medio (Mean Squared Error, MSE):

El Error Cuadrático Medio (Mean Squared Error, MSE) es otra métrica comúnmente utilizada para evaluar la precisión de un modelo de regresión. Es especialmente útil porque penaliza los errores grandes más que los pequeños, debido a la elevación al cuadrado de las diferencias.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Raíz del Error Cuadrático Medio (Root Mean Squared Error, RMSE):

La Raíz del Error Cuadrático Medio (Root Mean Squared Error, RMSE) es una medida utilizada para evaluar la precisión de un modelo de regresión. Es la raíz cuadrada del Error Cuadrático Medio (MSE) y proporciona una medida de error en las mismas unidades que los valores predichos, lo que facilita su interpretación.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

R^2 (Coeficiente de Determinación):

El coeficiente de determinación es una medida estadística que indica qué tan bien se ajusta un modelo de regresión a los datos observados. Proporciona la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes. Es una métrica clave en la evaluación del desempeño de los modelos de regresión.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Valor R^2 de 1

- Un valor de R^2 de 1.0 es **lo mejor que podemos conseguir**. Indica que no hay ningún error en la regresión.

Valor R^2 de 0


- Un valor de R^2 de 0 significa que la regresión **no es mejor que tomar el valor medio**, es decir no estamos usando ninguna información de otras variables.

Valor negativo de R^2

- Un valor negativo de R^2 , significa que estamos **estimando peor que usando la media**.

Suma Total de los Cuadrados (Total Sum of Squares, TSS):


La Suma Total de los Cuadrados (Total Sum of Squares, TSS) es una medida de la variabilidad total en los datos observados. Se utiliza en el contexto de la regresión para cuantificar la cantidad total de variación presente en los valores de la variable dependiente. La TSS se descompone en dos partes: la Suma de los Cuadrados de los Residuos (Residual Sum of Squares, RSS) y la Suma de los Cuadrados Explicada (Explained Sum of Squares, ESS).



$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Suma de los Cuadrados de los Residuos (Residual Sum of Squares, RSS):

La Suma de los Cuadrados de los Residuos (Residual Sum of Squares, RSS), también conocida como el Error Cuadrático Residual, mide la variabilidad en los datos que no puede ser explicada por el modelo de regresión. Es una métrica que ayuda a evaluar la precisión de un modelo, indicando cuánto los valores predichos se desvían de los valores observados.



$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Intervalo de confianza para β_1

Test de hipótesis sobre los coeficientes
estimados

(¿Existe evidencias para afirmar que hay relación
entre X e Y?)

$$IC = [\hat{\beta}_1 - 2.SE(\hat{\beta}_1), \hat{\beta}_1 + 2.SE(\hat{\beta}_1)]$$

$$Y = \beta_0 + \beta_1 \cdot X + \epsilon$$

El test de significación
individual tiene las
siguientes hipótesis



Hipótesis Nula

No hay relación entre X e Y; entonces

$$H_0 : \beta_1 = 0$$



Hipótesis Alternativa

Hay alguna relación entre X e Y; entonces

$$H_1 : \beta_1 \neq 0$$


Si $\beta_1=0$, entonces el modelo se reduce a $Y=\beta_0+\epsilon$

Por lo tanto X no estaría asociado a Y

Necesitamos determinar si nuestro estimador para β_1 está lo suficientemente lejos de cero, de forma que podamos estar seguros de que β_1 no es cero.

Un p-value pequeño indica que es poco probable observar un valor del estadístico como el observado o más extremo asumiendo que H_0 es verdadera.

Por lo tanto, si el p-value es chico podemos rechazar H_0 con baja probabilidad de equivocarnos.



¡Muchas gracias!