

Algoritmo de K-means

01


¿Qué es el algoritmo
k-means?



Es un método dentro de estos procesos de segmentación. El **k means** en clustering es, quizás, el instrumento más clásico tanto a la hora de agrupar como de aplicar el agrupamiento. Para implementarlo, se efectúa de forma previa, un número determinado de grupos. Este algoritmo busca los mejores centroides para efectuar la segmentación. Su objetivo es que los miembros de cada agrupación estén lo más próximos posible a su centroide.



02 Proceso



El algoritmo k-means funciona de manera iterativa y actualiza el centro de los clústeres de modo que va reduciendo las distancias con cada uno de sus individuos.



El procedimiento conlleva los siguientes pasos:

1. Determinar los centroides iniciales o semillas de los k grupos.
2. Asignar cada observacion al centroide más cercano según la distancia (ej. euclidea).
3. Con las observaciones clasificadas se recalculan los centroides de los k grupos. Si las distancias entre los nuevos y viejos centroides es mayor que un criterio de convergencia establecido, se vuelve al paso 2.
4. El proceso termina cuando se cumple el criterio de convergencia. Además, se fija un número de iteraciones que no debe superarse.




03

Funcionamiento

Conjunto de Datos


Partiendo de un conjunto de datos



Inicialización

Elegir el número de clústeres K : cuántos clústeres.


Seleccionar K puntos iniciales: Estos puntos pueden ser seleccionados aleatoriamente a partir de los datos o mediante algún método más sofisticado.



Asignación de Clústeres

Asignar cada punto de datos al clúster más cercano: Para cada punto en el conjunto de datos, se calcula la distancia desde el punto hasta cada uno de los K centros de clústeres (centroides).


Cada punto se asigna al clúster cuyo centroide está más cerca (según la distancia Euclidiana, aunque otras métricas también pueden usarse).



Actualización de Centroides



Recalcular los centroides: Una vez que todos los puntos han sido asignados a clústeres, se recalcula el centroide de cada clúster.

El nuevo centroide se calcula como el promedio de todos los puntos que pertenecen a ese clúster.




Repetición

Repetir los pasos de asignación y actualización: Los pasos de asignación de clústeres y actualización de centroides se repiten hasta que los centroides de los clústeres ya no cambien significativamente o hasta que se alcance un número máximo de iteraciones. La convergencia se considera alcanzada cuando los puntos no cambian de clústeres o los centroides se estabilizan.




Repetición

Repetir los pasos de asignación y actualización: Los pasos de asignación de clústeres y actualización de centroides se repiten hasta que los centroides de los clústeres ya no cambien significativamente o hasta que se alcance un número máximo de iteraciones. La convergencia se considera alcanzada cuando los puntos no cambian de clústeres o los centroides se estabilizan.



Resultados

Asignar los puntos finales a clústeres: Una vez que el algoritmo ha convergido, cada punto en el conjunto de datos estará asignado a uno de los K clústeres, y los centroides finales representarán los centros de estos clústeres.



Criterios de Parada

- **Los centroides dejan de cambiar.** Es decir, después de múltiples iteraciones, los centroides de cada clúster no cambian. Por lo que se asume que el algoritmo ha convergido.
- **Los puntos dejan de cambiar de clúster.** Parecido al anterior, pero esta vez no nos fijamos en los centroides, si no en los puntos que pertenecen a cada clúster. Cuando se observa que no hay un intercambio de clústers se asume que el modelo está entrenado.
- **Límite de iteraciones.** Podemos fijar un número máximo de iteraciones que queremos que nuestro algoritmo ejecute antes de pararlo. Cuando llega a ese número, se asume que el modelo no va a mejorar drásticamente y se para el entrenamiento.



¡Muchas gracias!