

Análisis de Componentes Principales (PCA)




El Análisis de Componentes Principales (PCA) es una técnica estadística que reduce la dimensionalidad de los datos manteniendo la mayor cantidad de variabilidad del conjunto de datos original.


Transforma los datos a un nuevo sistema de coordenadas, donde las nuevas variables (componentes principales) capturan la mayor varianza posible.



Conjunto de Datos Original en 3D



Datos Proyectados en 2D (PCA)




01 Objetivo de PCA



El objetivo principal del PCA es identificar las direcciones (componentes principales) en las que los datos varían más. Estas direcciones representan la mayor parte de la variabilidad presente en el conjunto de datos original. En otras palabras, PCA busca una nueva base para el espacio de datos donde las nuevas dimensiones (componentes) son las direcciones de máxima varianza.




Direcciones de Máxima Varianza (Componentes Principales)



02


Pasos Fundamentales de PCA




Centro de los Datos

La matriz de covarianza captura las varianzas y covarianzas entre las variables. Se calcula a partir de los datos centrados para entender cómo varían las características con respecto a cada una.

$$\mathbf{X}_{centrado} = \mathbf{X} - \bar{\mathbf{X}}$$







Cálculo de la Matriz de Covarianza

Primero, se centra el conjunto de datos restando la media de cada variable. Esto asegura que los componentes principales se calculen con datos centrados en el origen.

$$\mathbf{C} = \frac{1}{n-1} \mathbf{X}_{centrado}^T \mathbf{X}_{centrado}$$







Cálculo de los Valores y Vectores Propios

Los vectores propios representan las direcciones principales en las que los datos se dispersan, y los valores propios indican la cantidad de varianza que cada dirección explica.


$$C\mathbf{v}_i = \lambda_i \mathbf{v}_i$$






Ordenamiento de Componentes Principales

Los vectores propios se ordenan de acuerdo con sus valores propios de mayor a menor. Los primeros vectores propios capturan la mayor parte de la varianza en los datos.






Proyección de los Datos

Finalmente, los datos se proyectan en los componentes principales seleccionados, multiplicando los datos centrados por los vectores propios seleccionados.

$$\mathbf{X}_{reducido} = \mathbf{X}_{centrado} \mathbf{W}$$



03

Interpretación de Resultados

Interpretación de Resultados

Componentes Principales: Las nuevas variables obtenidas (componentes principales) son combinaciones lineales de las variables originales. Cada componente principal es ortogonal a los demás, lo que significa que cada uno captura una dirección distinta de la varianza en los datos.

Varianza Explicada: La proporción de la varianza total explicada por cada componente principal se puede utilizar para decidir cuántos componentes retener. El valor propio asociado con cada componente indica la cantidad de varianza explicada por ese componente.

Scree Plot: Un gráfico de codo (scree plot) muestra los valores propios en función de su orden. Ayuda a determinar el número óptimo de componentes principales a retener, buscando el punto donde la pendiente del gráfico se estabiliza.

¡Muchas gracias!