

Criteria de Selección de Modelos




Los criterios de selección de modelos son herramientas clave para comparar y elegir entre diferentes modelos estadísticos. Los más comunes son el **Criterio de Información de Akaike (AIC)** y el **Criterio de Información Bayesiano (BIC)**. Ambos ayudan a seleccionar el modelo que mejor equilibra el ajuste con la complejidad, penalizando los modelos con demasiados parámetros. ✨



01

Criterio de Información de Akaike (AIC)



Criterio de Información de Akaike (AIC)

El **AIC** es una medida utilizada para seleccionar el modelo que mejor equilibra la bondad del ajuste con la complejidad. Fue introducido por Hirotugu Akaike en 1974.


$$AIC = 2k - 2\ln(L)$$

- **k** es el número de parámetros del modelo.
- **L** es la máxima verosimilitud del modelo.

Penalización por Complejidad: El AIC penaliza los modelos más complejos (con más parámetros) para evitar el sobreajuste.

Comparación Relativa: El AIC es útil para comparar modelos. Un valor más bajo de AIC indica un mejor equilibrio entre ajuste y simplicidad.


Selección de Modelos en Diferentes Contextos



Regresión:

En un estudio de predicción de precios de viviendas, puedes comparar modelos de regresión con distintos conjuntos de características utilizando AIC. **El modelo con el menor AIC es preferible, ya que ofrece un buen ajuste con menos parámetros.**

Selección de Modelos en Diferentes Contextos




Series Temporales:

En el análisis de series temporales, como la predicción de ventas mensuales, puedes usar AIC para comparar diferentes modelos ARIMA. **El AIC te ayuda a determinar el modelo que mejor equilibra ajuste y complejidad.**

02

Criterio de Información Bayesiano (BIC)



Criterio de Información Bayesiano (BIC)


El **BIC**, también conocido como el Criterio de Información de Schwarz (SIC), es otro criterio para la selección de modelos que equilibra el ajuste y la complejidad. Fue propuesto por Gideon E. Schwarz en 1978.

$$BIC = \ln(n)k - 2\ln(L)$$

- **n** es el número de observaciones.
- **k** es el número de parámetros del modelo.
- **L** es la máxima verosimilitud del modelo.

El **BIC** penaliza más severamente los modelos con más parámetros en comparación con el **AIC**, y esta penalización aumenta con el tamaño de la muestra. Similar al AIC, el BIC se utiliza para comparar modelos, y un menor valor de BIC indica una mejor selección de modelo.


Ejemplos de Uso del BIC:



Modelos de Clustering:

En la segmentación de clientes mediante clustering, puedes usar el BIC para comparar diferentes números de clusters en un modelo de mezcla gaussiana. El número de clusters que minimiza el BIC es preferible, ya que balancea la complejidad del modelo con el ajuste.

Ejemplos de Uso del BIC:



Modelos de Mezcla:

En la identificación de subgrupos en datos genéticos, puedes utilizar BIC para comparar diferentes modelos de mezcla con distintos números de componentes y elegir el que mejor ajuste los datos sin sobreajustar.

¡Muchas gracias!