

DBSCAN y Algoritmos de Clustering Basados en Densidad



DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo de clustering basado en densidad que identifica clusters como regiones de alta densidad separadas por regiones de baja densidad. A diferencia de los métodos de clustering basados en centroides como K-means o los métodos jerárquicos, DBSCAN no requiere que el número de clusters sea especificado de antemano y puede identificar clusters de forma arbitraria y de diferentes formas. A continuación, se detalla el funcionamiento de DBSCAN y su comparación con otros métodos de clustering.



01

Funcionamiento del Algoritmo DBSCAN

DBSCAN se basa en dos parámetros principales:

- **Epsilon (ϵ):** Distancia máxima para considerar que dos puntos están en la misma vecindad.
- **MinPts (Número mínimo de puntos):** Número mínimo de puntos necesarios para formar un cluster (incluyendo el punto central).



Pasos del Algoritmo

Clasificación de los Puntos:



- **Punto Central:** Un punto es considerado un punto central si tiene al menos MinPts puntos dentro de una distancia ϵ . Esto incluye el punto mismo.
- **Punto de Borde:** Un punto que no es un punto central pero está dentro de la distancia ϵ de un punto central.
- **Punto de Ruido:** Un punto que no es ni un punto central ni un punto de borde. Es considerado ruido o outlier.

Terminación:

- El proceso continúa hasta que todos los puntos hayan sido asignados a un cluster o clasificados como ruido.

Expansión del Cluster:


- Comienza con un punto central y expande el cluster a los puntos de borde que están dentro de ϵ de ese punto central.
- Luego, se verifica si estos puntos de borde también pueden formar nuevos puntos centrales. El proceso se repite de manera recursiva.




02

Comparación con K-means y Clustering Jerárquico


DBSCAN




k-means



DBSCAN



K-Means



K-means es útil cuando tienes una idea clara del número de clusters y los clusters son aproximadamente esféricos. Es menos adecuado para datos con ruido o clusters de formas arbitrarias.

DBSCAN es ideal para identificar clusters con formas arbitrarias y manejar el ruido en los datos. No requiere especificar el número de clusters, pero puede ser sensible a la elección de los parámetros ϵ y MinPts.

Clustering Jerárquico proporciona una visión detallada de la estructura de clusters en un dendrograma y no requiere un número de clusters especificado, pero puede ser menos eficiente en grandes conjuntos de datos.



¡Muchas gracias!