

Evaluación de Clusters



La elección del hiperparámetro k es vital para el buen funcionamiento del algoritmo. Es lo que indica de qué forma se va a buscar la estructura interna de los datos. Como ha de explicitarse en la llamada del algoritmo, es un valor que hay que determinar por métodos externos a KMeans. Hay dos métodos clásicos para hallar el valor óptimo de k en función de los datos de lo que disponemos ✨



01

Elbow Curve o Curva de Codo



Es la representación más utilizada. Es una curva que expresa la inercia propia del agrupamiento en función del número de clusters que buscamos. Lo que hay que buscar en la curva es lo que se denomina <codo de la función>, es decir, el cambio brusco en la inercia. Nos indica que, a partir de ese k , el valor de la inercia se estabiliza e indica los mejores valores de k . Puede ser que la curva no marque un codo muy evidente, por lo que se suele probar varios valores de k .




A medida que introducimos centroides reducimos de igual forma el valor de WCSS. Cada punto de datos se mueve aún más cerca de su centroide y el valor de WCSS disminuye. Se da el caso en el que si utilizamos el mismo número de centroides que puntos de datos, de manera que cada dato tenga un clúster, el valor de WCSS sería cero. Sin embargo, sabemos que en ese caso no estaríamos agrupando adecuadamente, realmente ni siquiera lo estamos haciendo.



Estaríamos sobre-ajustando, “sobre-agrupando”. Y nuestro proceso de k-means ni siquiera estaría realizando su función de agrupación de conjuntos de objetos.

Entonces, ¿cuál es el punto óptimo antes del nivel cero?



Vemos los resultados de WCSS a medida que introducimos centroides (valor K = number of clusters). Lo que se entiende por método del codo es buscar el punto de la gráfica donde se produce el último cambio sustancial y se producen disminuciones de WCSS graduales e insignificantes. Buscamos este punto codo. El punto en donde si agregamos más centroides no vamos a reducir el error sustancialmente.

Este punto, que nos daría el equilibrio entre un grupos de clústeres compactos, no siempre será tan obvio como en el ejemplo. El científico de datos deberá tomar la decisión basándose en el método del codo, que le dará una pista de donde buscar.



02

Método de la silueta



Es una medida similar a la inercia que mide la variación intracluster pero, además, también mide lo seguro que se está de que un punto pertenezca a un cluster. Así se identifican puntos mal asignados o puntos que se encuentran en medio de dos clusters. Lo que se hace es hacer un bucle que pase por todos los posibles valores de k , representar el coeficiente de Silhouette y quedarse con el mejor agrupamiento. Cuanto más alto es el coeficiente de Silhouette, mejor es el agrupamiento.



Para calcular este coeficiente nos servimos de dos distancias: **a** la distancia media intra-clúster y **b** la distancia media a las observaciones del clúster más cercano.

$$S = \frac{b - a}{\max(a, b)}$$




Para poder hacer un análisis para determinar el mejor valor de K se usan los gráficos de silueta:

En el eje de coordenadas representamos el coeficiente de silueta y en el de ordenadas el número del clúster.

La línea vertical discontinua determina el coeficiente de silueta medio para todos los clústeres en los conjuntos de datos.

Vemos que el valor del coeficiente de silueta medio es mayor en el primer gráfico que en el segundo, lo que nos indicaría que la agrupación en dos clústeres sería más óptima que en 3 clústeres. Vemos que cada clúster tiene a su vez un tamaño diferente. Se representa de esa manera el tamaño del mismo, el número de datos que lo componen.




Para poder hacer un análisis para determinar el mejor valor de K se usan los gráficos de silueta:

En el eje de coordenadas representamos el coeficiente de silueta y en el de ordenadas el número del clúster.

La línea vertical discontinua determina el coeficiente de silueta medio para todos los clústeres en los conjuntos de datos.

Vemos que el valor del coeficiente de silueta medio es mayor en el primer gráfico que en el segundo, lo que nos indicaría que la agrupación en dos clústeres sería más óptima que en 3 clústeres. Vemos que cada clúster tiene a su vez un tamaño diferente. Se representa de esa manera el tamaño del mismo, el número de datos que lo componen.



Mejor valor de K = 3

¡Muchas gracias!