

Estrategias de Selección de Variables



La selección de variables es fundamental en el análisis de datos y la creación de modelos, ya que permite reducir el número de características y enfocarse en aquellas que aportan mayor valor. Esto mejora el rendimiento del modelo, facilita su interpretación, reduce el riesgo de sobreajuste y acelera los tiempos de entrenamiento.



01 Métodos Basados en Filtros




Los métodos basados en filtros son técnicas de selección de características que evalúan la importancia de las variables en función de medidas estadísticas sin utilizar un modelo de aprendizaje automático. Estos métodos se aplican antes de entrenar un modelo y ayudan a reducir la dimensionalidad al seleccionar las características más relevantes.



Método de la Correlación

Descripción: Este método evalúa la correlación entre cada característica y la variable objetivo. Las características con alta correlación con la variable objetivo se seleccionan, mientras que las de baja correlación se descartan.

Ejemplo: En un problema de regresión, se utiliza el coeficiente de correlación de Pearson para medir la relación entre cada característica y la variable dependiente. Las características con un coeficiente más cercano a 1 o -1 son las que se consideran más relevantes.



Prueba de Chi-Cuadrado

Descripción: Utiliza la prueba estadística de chi-cuadrado para evaluar la independencia entre las características y la variable objetivo. Este método es adecuado para variables categóricas, y permite identificar las características que tienen una dependencia significativa con la variable objetivo.


Ejemplo: En una tarea de clasificación, se utiliza la prueba chi-cuadrado para seleccionar características que muestran una relación significativa con las diferentes clases. **Las características que tienen una mayor dependencia con la clase se consideran más relevantes.**

Feature	Chi-Squared Score	p-Value
Feature_1	70.356	4.95e-17
Feature_3	46.113	1.12e-11
Feature_4	22.231	2.42e-06
Feature_5	13.423	2.49e-04
Feature_2	0.216	0.642

Análisis de Varianza (ANOVA)

Descripción: ANOVA compara la varianza de las características entre diferentes clases para identificar aquellas que muestran diferencias significativas en sus medias. Es útil para seleccionar características relevantes en problemas de clasificación.


Ejemplo: En un problema de clasificación, ANOVA evalúa qué características tienen variabilidad significativa entre las clases, ayudando a seleccionar las que mejor separan las categorías.



Coeficientes de Importancia (para Modelos Lineales)

Descripción: En modelos lineales, como la regresión lineal o logística, la importancia de cada característica se mide mediante los coeficientes del modelo. Las características con coeficientes de mayor magnitud (en valor absoluto) se consideran más relevantes.

Ejemplo: En un modelo de regresión lineal, se seleccionan las características más importantes basándose en los valores absolutos de sus coeficientes, priorizando aquellas con mayor influencia sobre la variable objetivo.




02

Eliminación Recursiva de Características (RFE)



RFE es un método de selección de características que utiliza un enfoque iterativo para eliminar las menos importantes, basado en un modelo de aprendizaje automático. A diferencia de los métodos basados en filtros, RFE emplea un modelo para evaluar la importancia de las características en cada iteración.






Etapas


- **Inicialización:** Se comienza con todas las características disponibles y se entrena un modelo de aprendizaje automático, como una máquina de soporte vectorial (SVM) o un modelo de regresión.
- **Evaluación de Importancia:** Se evalúa la importancia de cada característica utilizando el modelo entrenado, ya sea calculando coeficientes en modelos lineales o usando métricas específicas, como la importancia de características en árboles de decisión.
- **Eliminación:** Se elimina la característica menos importante (la que tiene el menor coeficiente de importancia o la menor contribución al rendimiento del modelo).
- **Iteración:** Se reentrena el modelo con las características restantes y se repite el proceso de evaluación y eliminación, hasta alcanzar el número deseado de características o un criterio de parada.
- **Selección Final:** Al final del proceso, se selecciona el subconjunto de características que maximiza el rendimiento del modelo.

Proceso de Eliminación Recursiva de Características (RFE)



03

Comparación entre Métodos Basados en Filtros y RFE



Métodos Basados en Filtros vs RFE

Criterio	Métodos Basados en Filtros	RFE (Eliminación Recursiva de Características)
Independencia del Modelo	No dependen de un modelo; se basan en estadísticas generales de las características.	Dependen de un modelo de aprendizaje automático para evaluar la importancia.
Computación	Más rápidos, no requieren entrenamiento de un modelo en cada paso.	Computacionalmente más costoso, ya que implica entrenar el modelo iterativamente.
Interpretabilidad	Evaluación directa de las características sin influencia de un modelo.	Evaluación basada en el rendimiento del modelo, más relevante en algunos contextos.
Flexibilidad	General y aplicable antes de la modelización.	Centrado en el rendimiento del modelo, mejorando la precisión del modelo final.

¡Muchas gracias!