


Evaluación de Modelos No Supervisados

Introducción a las Métricas de Evaluación en Aprendizaje No Supervisado



El aprendizaje no supervisado es una rama del aprendizaje automático que se centra en identificar patrones y estructuras ocultas en datos no etiquetados. A diferencia del aprendizaje supervisado, donde se dispone de datos etiquetados para entrenar modelos y evaluar su desempeño, en el aprendizaje no supervisado no existen etiquetas predefinidas. En su lugar, se utilizan técnicas que exploran y revelan la estructura intrínseca de los datos.

Para evaluar la calidad y efectividad de los algoritmos de aprendizaje no supervisado, es crucial disponer de métricas que nos ayuden a medir y comprender los resultados obtenidos. Estas métricas proporcionan una manera de evaluar la cohesión y separación de los clusters, la optimización del número de clusters, y la capacidad de los modelos para representar adecuadamente los datos en espacios de menor dimensión.



Índice de Silueta



El Índice de Silueta mide la calidad de la agrupación de los datos. Se calcula para cada punto de datos y proporciona una medida de cuán bien se ha agrupado un punto con respecto a los puntos en su propio grupo y a los puntos en el grupo más cercano.



El valor del índice de silueta varía entre -1 y 1. Un valor cercano a 1 indica que el punto está bien agrupado, mientras que un valor cercano a -1 indica que el punto podría estar mal agrupado. Es útil para evaluar la cohesión y separación de los clusters en técnicas como K-means.



Coeficiente de Davies-Bouldin



Este coeficiente evalúa la calidad de los clusters en función de la distancia promedio entre los puntos de un cluster y la distancia entre clusters. Se calcula como la media de las razones de la dispersión intra-cluster a la distancia entre clusters para cada cluster.



Valores más bajos indican una mejor calidad de clustering, ya que implican que los clusters son más compactos y están mejor separados. Es útil para comparar la calidad de diferentes agrupaciones, especialmente en métodos de clustering como K-means o algoritmos jerárquicos.



Método del Codo (Elbow Method)



El Método del Codo se utiliza para determinar el número óptimo de clusters en un conjunto de datos. Se basa en graficar la varianza explicada en función del número de clusters y buscar el "codo" en la gráfica, que indica el punto donde la adición de más clusters proporciona una mejora marginal en la explicación de la varianza.



El "codo" en la gráfica es subjetivo, pero es el punto donde la tasa de disminución de la varianza se estabiliza. Se aplica principalmente en el clustering para elegir el número adecuado de clusters en algoritmos como K-means.



Varianza Explicada (PCA)



En el análisis de componentes principales (PCA), la varianza explicada se refiere a la proporción de la varianza total de los datos que es capturada por cada componente principal. Ayuda a determinar cuántos componentes son necesarios para representar adecuadamente los datos.



La varianza explicada se expresa como una proporción o porcentaje, donde valores más altos indican que el componente explica una mayor parte de la varianza en los datos. Es útil para la reducción de dimensionalidad, ayudando a decidir cuántos componentes principales retener para representar los datos de manera efectiva.

Cada una de estas métricas proporciona una perspectiva diferente sobre la efectividad de las técnicas de aprendizaje no supervisado. El uso combinado de estas métricas permite una evaluación más completa y precisa, ayudando a mejorar la comprensión y el rendimiento de los modelos en diversas aplicaciones de análisis de datos.





Cross Validation



La Validación cruzada o cross validation es un método que consiste en evaluar y probar el rendimiento de un modelo de machine learning, con el fin de encontrar un mejor modelo rápidamente. Esta técnica ayuda a la comprensión y aplicación de este modelado predictivo, siendo fácil y sencilla de aplicar.




La idea de la validación cruzada es simple: en lugar de usar diferentes sets para entrenamiento y validación ¡en la validación cruzada usaremos todos los datos!

Validación Cruzada

La validación cruzada es una técnica utilizada para evaluar la capacidad predictiva de un modelo de machine learning, asegurando que este se generalice bien a datos no vistos. Este método implica dividir el dataset original en múltiples subconjuntos, conocidos como "folds". El proceso típico sigue estos pasos:

- **División del Dataset:** Se divide el dataset en k subconjuntos de aproximadamente el mismo tamaño. Este valor k se elige según la necesidad del análisis, siendo común el uso de $k = 5$ o $k = 10$
- **Entrenamiento y Evaluación:**
 - Para cada uno de los k subconjuntos, el modelo se entrena usando $k-1$ de esos subconjuntos como datos de entrenamiento.
 - El subconjunto restante se usa como conjunto de prueba.
 - Este proceso se repite k veces, cambiando el subconjunto de prueba en cada iteración.
- **Promedio de Resultados:** Se calculan los resultados de evaluación (como precisión, error, etc.) en cada una de las k iteraciones. Luego, se promedian estos resultados para obtener una medida final del desempeño del modelo.





Ventaja de la Validación Cruzada





Uso Eficiente de Datos: Maximiza el uso de los datos disponibles, ya que cada dato se utiliza tanto para entrenamiento como para prueba.



Evaluación Robusta: Proporciona una estimación más fiable del rendimiento del modelo, ya que se evalúa en múltiples particiones del dataset.

Tipos comunes de Validación Cruzada

- **k-Fold Cross Validation:** Como se describió, el dataset se divide en k partes.
- **Leave-One-Out Cross Validation (LOOCV):** Es un caso extremo donde k es igual al número de observaciones en el dataset. Cada iteración usa una sola observación como conjunto de prueba y el resto como conjunto de entrenamiento.
- **Stratified k-Fold Cross Validation:** Similar a k-Fold, pero se asegura de que cada fold mantenga la proporción original de clases en problemas de clasificación, proporcionando así una evaluación más equilibrada.





Hiperparámetros



Los hiperparámetros son las características externas de un modelo, **no se "aprenden"**, son valores que tiene que definirse cuando se implementa el modelo, antes de entrenarlo.

Un ejemplo es el valor k en el algoritmo K-means, o el nivel máximo de un árbol.



Los parámetros son las características internas de un modelo, son valores estimados a partir del entrenamiento con los datos.

Un ejemplo son los coeficientes de una regresión lineal.




Los parámetros son las características internas de un modelo, son valores estimados a partir del entrenamiento con los datos.

Un ejemplo son los coeficientes de una regresión lineal.


Hiperparámetros

No podemos saber a priori cuáles son los mejores valores de los hiperparámetros del modelo para resolver un problema determinado. Además, mientras una configuración específica de hiperparámetros puede generar una buena performance del modelo para un determinado dataset, en otro similar quizás no sea así.

Por lo tanto, **la optimización o ajuste de los hiperparámetros (hyperparameters tuning)**, es decir, la selección de un conjunto óptimo de valores para los hiperparámetros, es una parte esencial del machine learning. Sin embargo, los modelos pueden tener muchos hiperparámetros, y encontrar la mejor combinación se convierte en un problema de búsqueda de información.



Fuente: [Medium](#)



Hiperparámetros


Vamos a analizar dos métodos de ajuste de hiperparámetros: Grid Search y Random Search. Ambos métodos siguen un proceso simple:

Para cada combinación de valores de los hiperparámetros:

- Aplican los valores sobre el conjunto de entrenamiento.
- Evalúan con validación cruzada.
- Registran el puntaje obtenido.

Al final de todas las búsquedas:

- Seleccionan la combinación con el puntaje más alto.
- Aplican la combinación seleccionada sobre el conjunto de entrenamiento.
- Predicen sobre el conjunto de prueba.





Hyperparameter Tuning




GridSearch busca la mejor combinación de hiperparámetros dentro de una grilla (grid) especificada previamente. La búsqueda es exhaustiva para cada valor de la grilla.




RandomSearch selecciona en forma aleatoria un subset de los hiperparámetros



Es importante tener en cuenta el costo a nivel de cómputo de evaluar todas las combinaciones de los valores de los hiperparámetros. Por lo tanto, en algunos casos vamos a tener que elegir una grilla reducida, o usar RandomSearch que selecciona un subset de combinaciones.




Grid Search



Random Search

Cómo se implementa



Para implementar una búsqueda de hiperparámetros en sklearn, debemos considerar los siguientes elementos:

1. **Un estimador:** Es decir, un modelo sobre el cual queremos trabajar.
2. **Un espacio de parámetros:** El rango de valores de los hiperparámetros sobre los cuales se realizará la búsqueda.
3. **Un método de búsqueda:** La estrategia utilizada para buscar entre los modelos candidatos (por ejemplo, RandomSearch o GridSearch).
4. **Un esquema de validación cruzada:** Seleccionando la cantidad de folds para dividir el dataset.
5. **La métrica de evaluación:** El criterio utilizado para elegir el mejor modelo.

¡Muchas gracias!