

Fundamentos de Clustering

01

¿Qué es clustering?





Es un conjunto de procesos que tiene como objetivo agrupar en grupos a individuos no etiquetados para crear subconjuntos de datos. Cada uno de ellos recibe el nombre de clúster. Se trata de una colección de objetos o datos que guardan similitudes entre ellos. Sin embargo, también tienen las suficientes características diferenciadoras respecto al resto de los elementos como para justificar la creación de un segmento independiente.



Analisis de conglomerados

Objetivo

- Identificar grupos relativamente homogéneos con base en un conjunto de variables específicas.
- Clasificar a las observaciones en grupos donde cada grupo o conglomerado sea homogéneo internamente y heterogéneos entre ellos.




¿Cómo se agrupan?

El criterio básico para cualquier agrupación en clúster es la **distancia**.

Los objetos que están cerca unos de otros deben pertenecer al mismo clúster, y los objetos que están lejos unos de otros deben pertenecer a clústeres diferentes.

Los algoritmos de clustering más utilizados son **K-means** y **Hierarchical clustering**.



02

Tipos de distancias entre individuos

Dependiendo del tipo de variables de la matriz original (cuantitativos, cualitativos o rango de observaciones), podemos definir las distancias idóneas para realizar un análisis cluster. El objetivo de seleccionar el tipo de distancia a nuestros datos es para poder obtener la matriz de distancias (o proximidades).




Distancia Euclídea (o Euclidiana).

Es la distancia más corta situada entre dos objetos definidos en el espacio por variables usadas en el análisis. Normalmente es la distancia más apropiada y usada cuando se trata de variables cuantitativas.

Distancia de Manhattan.

Es la distancia entre dos puntos siguiendo el reticulado de la cuadrícula. Mientras que en la distancia Euclídea solo hay una recta posible, en la distancia Manhattan pueden haber varias rutas con la misma longitud.





03

Tipos de agrupamientos

Se pueden analizar alternativas para distintos números de grupos. Dependiendo del problema que haya que resolver o de los objetivos del proyecto, se elige un proceso de agrupamiento u otro.

Algunos de los métodos de agrupamiento que se suelen usar:

- Método del enlace **simple** o vecino más próximo.
- Método del enlace **completo** o vecino más lejano.
- Método del enlace **promedio** o vinculación intergrupo.
- Método del **centroide**.
- Método de varianza mínima o de **Ward**.



Método del enlace simple o vecino más próximo

El método de Enlace Simple también se conoce como método de **Enlace Mínimo (MIN)**.

En el método de Enlace Simple, la distancia entre dos clusters se define como la ***distancia mínima entre un objeto*** (punto) ***de un cluster y un objeto*** (punto) ***del otro cluster***. Este método también se conoce como método del vecino más próximo.


Ventajas del método Simple Linkage

- Los métodos Simple Linkage pueden manejar formas no elípticas.
- Los algoritmos de Simple Linkage son los mejores para capturar clusters de diferentes tamaños.

Desventajas del método Simple Linkage

- Los métodos Simple Linkage son sensibles al ruido y a los valores atípicos.
- Esto significa que los métodos Simple Linkage no pueden agrupar clusters correctamente si hay ruido entre los clusters.

Método del enlace simple o vecino más próximo



Método del enlace completo o vecino más lejano

El método de Enlace completo también se conoce como método de **Enlace máximo (MAX)**.

En la técnica de Enlace completo, la distancia entre dos clusters se define como la ***distancia máxima entre un objeto*** (punto) ***de un cluster y un objeto*** (punto) ***del otro cluster***. Este método también se conoce como método del vecino más lejano.


Ventajas del método Complete Linkage

- Los algoritmos Complete Linkage son menos susceptibles al ruido y a los valores atípicos.
- Esto significa que el método Complete Linkage también funciona bien a la hora de separar conglomerados si hay algún ruido entre los conglomerados.

Desventajas del método Complete Linkage

- Los métodos de enlace completo tienden a romper los conglomerados grandes.
- Complete Linkage se inclina hacia los clusters globulares.

Método del enlace completo o vecino más lejano



Método del enlace promedio o vinculación intergrupo

En la técnica Average Linkage, la distancia entre dos clusters es la **distancia media entre el punto de cada cluster y cada punto del otro cluster**.

Este método también se conoce como método de grupos de pares no ponderados con media aritmética


Ventajas del método Average Linkage

- El método Average Linkage también funciona bien a la hora de separar clusters si hay ruido entre los clusters.

Desventajas del método Average Linkage

- El método Average Linkage está sesgado hacia los conglomerados globulares.

Método del enlace promedio o vinculación intergrupo



Método del centroide

En el enfoque Centroid Linkage, la distancia entre los dos conjuntos o clusters es la **distancia entre dos vectores medios de los conjuntos (clusters)**.

En cada etapa, combinamos los dos conjuntos que tienen la distancia centroide más pequeña. En palabras sencillas, **es la distancia entre los centroides de los dos conjuntos**.


Ventajas del método Centroid Linkage

- El método Centroid Linkage también separa bien los conglomerados si hay ruido entre ellos.

Desventajas del método Centroid Linkage

- Al igual que los métodos Complete Linkage y Average Linkage, el método Centroid Linkage también está sesgado hacia los conglomerados globulares.

Método del centroide



Método de varianza mínima o de Ward.

El método de vinculación de Ward es la similitud de dos conglomerados. Se basa en el **aumento del error cuadrático cuando se fusionan dos conglomerados**, y es similar a la media de grupo si la distancia entre puntos es la distancia al cuadrado.


Ventajas del método Ward's Linkage

- En muchos casos, se prefiere el método Ward's Linkage, ya que suele producir mejores jerarquías de conglomerados.
- El método de Ward es menos susceptible al ruido y a los valores atípicos.

Desventajas del método Ward's Linkage

- El método Ward's Linkage está sesgado hacia los clusters globulares.

Método de variância mínima o de Ward.



¡Muchas gracias!