


# Preparación de Datos para Aprendizaje no Supervisado

# Limpieza y preparación de datos

En 2009 Mike Driscoll (data scientist y CEO de Metamarkets) popularizó el término "data munging" para referirse al arduo proceso de limpiar, preparar y validar los datos.

## ¿Cómo invierte su tiempo un data scientist?





# Limpieza de Datos



## **Resolver problemas de formato y asignar los tipos correctos de datos:**

Por ejemplo cuando al pasar de CSV a Pandas una fecha no se importa correctamente. Ej:  
20090609231247 en lugar de 2009-06-09 23:12:47.



## **Estandarizar categorías:**

Cuando los datos se recolectaron con un sistema que no tiene los valores tipificados, valores que representan las mismas categorías pueden estar expresados de forma distinta, por ejemplo Arg, AR y Argentina.



# Limpieza de Datos



## **Corregir valores erróneos:**

Por ejemplo un valor numérico o inválido para describir el género. O una edad representada por un número negativo o mucho mayor que 100



## **Completar datos faltantes:**


Los datasets del mundo real suelen venir con datos faltantes que responden a información que se perdió o nunca se recolectó.

Existen varias técnicas para completar datos faltantes. Al proceso de completar datos faltantes se lo llama "imputación".



## **Organizar correctamente el dataset:**

Es importante estructurar las filas y columnas de la forma más conveniente. Para hacerlo se pueden aplicar las reglas del "tidy data".



# ¿Por qué Normalizar?

Manejo de cantidades en diferentes unidades o escalas.  
Para no favorecer a ninguna variable en particular al calcular la distancia, debemos estandarizar y deshacernos de las unidades.





# ¿Qué es un Hiperparámetro?

En machine learning, un hiperparámetro es un parámetro cuyo valor se utiliza para controlar el proceso de aprendizaje. Por el contrario, los valores de los parámetros se derivan a través del entrenamiento.

Los hiperparámetros se pueden clasificar como:

- hiperparámetros de modelo
- hiperparámetros de algoritmo

Diferentes algoritmos de aprendizaje requieren diferentes hiperparámetros, algunos algoritmos simples (como la regresión de mínimos cuadrados ordinarios) no requieren ninguno.

¡Muchas gracias!