

Principios de Reducción de la Dimensionalidad




La reducción de dimensionalidad es una técnica esencial en el análisis de datos que tiene como objetivo disminuir el número de variables o dimensiones en un conjunto de datos, preservando la mayor cantidad de información relevante posible. Esto mejora la eficiencia de los algoritmos, facilita la interpretación de los datos y optimiza la calidad de los modelos de aprendizaje automático, especialmente en contextos de datos de alta dimensión.




3D vs 2D

- A la izquierda, se ven los datos en sus 3 dimensiones originales.
- A la derecha, se observa cómo los datos se proyectan en 2 dimensiones, manteniendo la estructura general.



01

Importancia y Fundamentos de la Reducción de Dimensionalidad





Importancia de la Reducción de Dimensionalidad

En conjuntos de datos con muchas dimensiones, interpretar y visualizar los resultados puede ser complicado. La reducción de dimensionalidad permite representar los datos en un espacio más pequeño, haciendo que los patrones sean más fáciles de identificar.

Ejemplo

Reducir un conjunto de datos con cientos de variables a dos o tres dimensiones permite crear gráficos más sencillos y visuales.








Mejora del Rendimiento del Modelo

Reducir el número de dimensiones elimina variables irrelevantes o redundantes, lo que mejora el rendimiento del modelo al reducir el ruido.

Ejemplo

En conjuntos de datos de imágenes, la reducción de dimensionalidad puede eliminar características no relevantes y mejorar la precisión de un modelo de clasificación.







La Maldición de la Dimensión

La maldición de la dimensión se refiere a los problemas que surgen al trabajar con datos de alta dimensionalidad, como la esparsidad y la dificultad para medir distancias. Reducir la dimensionalidad mitiga estos problemas.

Ejemplo

En problemas de clustering, la reducción de dimensiones puede ayudar a identificar mejor los grupos y evitar el sobreajuste.






Simplificación del Modelo

Reducir la dimensionalidad simplifica el modelo, mejorando su capacidad para generalizar a nuevos datos y evitando el sobreajuste.

Ejemplo

Reducir el número de características en un modelo de regresión puede evitar que se ajuste demasiado a los datos de entrenamiento.




02

Métodos Comunes de Reducción de Dimensionalidad

PCA (Análisis de Componentes Principales)

PCA es una técnica lineal que transforma los datos a un nuevo sistema de coordenadas, donde las dimensiones (componentes principales) están ordenadas por la varianza. Los primeros componentes principales capturan la mayor parte de la varianza.


Es útil para reducir la dimensionalidad manteniendo la mayor cantidad de información posible.



t-SNE

t-SNE es una técnica no lineal que reduce la dimensionalidad manteniendo la estructura de los vecinos locales en datos de alta dimensión. Es ideal para visualización de datos complejos en 2 o 3 dimensiones.


A menudo se utiliza en datos complejos donde es necesario preservar las relaciones locales.



Selección de Características

La selección de características basada en modelos elige un subconjunto relevante de características, en lugar de transformar las existentes. Esto permite mantener las características originales más importantes para el problema.


Por ejemplo, los árboles de decisión y Random Forest pueden seleccionar las características que contribuyen más a la predicción.



ICA (Análisis de Componentes Independientes)

ICA busca transformar los datos en componentes que son estadísticamente independientes entre sí. Es útil en situaciones donde las dimensiones subyacentes son independientes y deben ser separadas.

Ideal para datos donde las características originales están mezcladas y se busca recuperar las componentes independientes.



¡Muchas gracias!