


Aprendizaje No Supervisado



Programa



Aprendizaje no supervisado

Fundamentación

El curso tiene como objetivo proporcionar a los estudiantes conocimientos y habilidades prácticas en técnicas de aprendizaje no supervisado y reducción de la dimensión.

Objetivos de aprendizaje

Se espera que los estudiantes puedan:

- Estudiar la teoría y aplicaciones prácticas de algoritmos de clustering, reducción de dimensionalidad y selección de variables.
- Aprender a utilizar y comparar algoritmos de clustering como K-means, clustering jerárquico, DBSCAN, y evaluar su efectividad.
- Aplicar estrategias de selección de variables y técnicas de reducción de dimensionalidad como PCA, LDA, T-SNE y UMAP para mejorar el rendimiento de los modelos de IA.
- Utilizar Python y bibliotecas relevantes para implementar, evaluar y visualizar algoritmos de aprendizaje no supervisado.
- Aplicar técnicas de evaluación y validación cruzada para asegurar la robustez y precisión de los modelos no supervisados.

Criterios de aprobación

- Realizar las actividades de Playground (100% de completitud).
- Aprobación de los checkpoints de conocimiento de cada módulo de aprendizaje.
- Aprobación del cuestionario final del curso.

Contenidos

Módulo 1 - Bienvenida

Clase 1 - Bienvenida

- Programa del curso
- Presentación del curso
- Cuestionario de autoevaluación

Módulo 2 - Introducción al Aprendizaje no Supervisado

Clase 2 - Entorno de Desarrollo

- Configuración del IDE (VS Code)
- Instalaciones necesarias

Clase 3 - Principios del Aprendizaje no Supervisado

- Definición y fundamentos del aprendizaje no supervisado
- Diferencias entre aprendizaje supervisado y no supervisado

Clase 4 - Aplicaciones del Aprendizaje no Supervisado

- Ejemplos prácticos y casos de uso
- Importancia del aprendizaje no supervisado en la IA

Clase 5 - Técnicas Comunes en Aprendizaje no Supervisado

- Descripción de las principales técnicas utilizadas
- Comparación de diferentes enfoques

Clase 6 - Preparación de Datos para Aprendizaje no Supervisado

- Limpieza y preprocesamiento de datos
- Selección de características relevantes

Clase 7 - Evaluación de Modelos No Supervisados

- Métricas y métodos de evaluación
- Validación cruzada y ajuste de hiperparámetros

Clase 8 - Checkpoint de contenidos

- Primera evaluación de conocimientos

Módulo 3 - Clustering y K-means

Clase 9 - Fundamentos de Clustering

- Concepto y tipos de clustering
- Importancia y aplicaciones del clustering

Clase 10 - Clustering Jerárquico

- Introducción al clustering jerárquico
- Dendrogramas y su interpretación

Clase 11 - Algoritmo de K-means

- Funcionamiento del algoritmo K-means
- Implementación práctica de K-means en Python

Clase 12 - Evaluación de Clusters

- Métodos para evaluar la calidad de los clusters
- Determinación del número óptimo de clusters

Clase 13 - DBSCAN y Algoritmos de Clustering Basados en Densidad

- Funcionamiento del algoritmo DBSCAN
- Comparación con K-means y clustering jerárquico

Clase 14 - Aplicaciones Prácticas del Clustering

- Casos de uso en diferentes industrias
- Ejemplos prácticos y análisis de resultados

Clase 15 - Checkpoint de contenidos

- Segunda evaluación de conocimientos

Módulo 4 - La Maldición de la Dimensión y Selección de Variables

Clase 16 - Comprender la Maldición de la Dimensión

- Definición y efectos de la maldición de la dimensión
- Desafíos y problemas comunes

Clase 17 - Estrategias de Selección de Variables

- Métodos basados en filtros
- Eliminación recursiva de características (RFE)

Clase 18 - Criterios de Selección de Modelos

- Criterio de Información de Akaike (AIC)
- Criterio de Información Bayesiano (BIC)
- Aplicaciones prácticas y ejemplos

Clase 19 - Selección de Variables con Regularización

- Uso de Lasso y Ridge para selección de variables

- Implementación práctica en Python

Clase 20 - Selección de Variables con Métodos Embedded

- Árboles de decisión y Random Forest para selección de variables
- Implementación práctica en Python

Clase 21 - Checkpoint de contenidos

- Tercer evaluación de conocimientos

Módulo 5 - Reducción de la Dimensionalidad

Clase 22 - Principios de Reducción de la Dimensionalidad

- Importancia y fundamentos de la reducción de dimensionalidad
- Métodos comunes de reducción

Clase 23 - Análisis de Componentes Principales (PCA)

- Teoría detrás del PCA
- Implementación práctica de PCA en Python

Clase 24 - Aplicaciones de PCA

- Visualización de datos de alta dimensionalidad
- Aplicaciones de PCA en machine learning

Clase 25 - Análisis Discriminante Lineal (LDA)

- Fundamentos y teoría del LDA
- Implementación práctica de LDA en Python

Clase 26 - T-SNE para Visualización

- Introducción a T-SNE
- Aplicaciones prácticas de T-SNE

Clase 27 - UMAP para Reducción de Dimensionalidad

- Fundamentos y teoría de UMAP
- Implementación práctica de UMAP en Python

Clase 28 - Comparación de Técnicas de Reducción de Dimensionalidad

- Ventajas y desventajas de PCA, LDA, T-SNE y UMAP
- Casos de uso recomendados para cada técnica

Clase 29 - Checkpoint de contenidos

- Cuarta evaluación de conocimientos

Módulo 6 - Cierre de Curso

Clase 30 - Despedida

- Resumen del curso

Clase 31 - Evaluación Integral

- Evaluación integral de los conocimientos trabajados