


Técnicas Comunes en Aprendizaje no Supervisado

01

Principales técnicas utilizadas

Clustering (Agrupamiento)

K-Means: Agrupa los datos en un número fijo de clusters (k) minimizando la varianza dentro de cada cluster. Es eficiente pero requiere que se especifique el número de clusters de antemano.



Clustering (Agrupamiento)

Hierarchical Clustering (Clustering Jerárquico):

Construye un árbol de clusters mediante la combinación o división iterativa de clusters. No requiere especificar el número de clusters previamente, pero puede ser computacionalmente costoso.


DBSCAN (Density-Based Spatial Clustering of Applications with Noise): Agrupa datos basados en la densidad de puntos y puede identificar clusters de forma arbitraria. Es útil para datos con formas de clusters no esféricas y puede identificar ruido en los datos.



Análisis de Componentes Principales

PCA (Principal Component Analysis): Proyecta los datos a un espacio de menor dimensión mientras retiene la mayor varianza posible. Es útil para visualización y para preparar datos para otros algoritmos.

Factor Analysis: Similar al PCA, pero asume que las variables observadas son influenciadas por un número menor de factores subyacentes. Es útil para modelos de estructuras de correlación y reducción de dimensionalidad.



Reducción de Dimensionalidad

t-SNE (t-Distributed Stochastic Neighbor Embedding):

Específicamente diseñado para visualización en 2D o 3D de datos de alta dimensión, preservando la estructura local y global de los datos.

Autoencoders: Redes neuronales que aprenden una representación compacta (codificación) de los datos para reducción de dimensionalidad, permitiendo una reconstrucción precisa de los datos originales.



Modelado de Temas


LDA (Latent Dirichlet Allocation): Un modelo generativo que asume que los documentos son mezclas de temas y los temas son mezclas de palabras. Se usa para descubrir la estructura temática en grandes colecciones de texto.

NMF (Non-Negative Matrix Factorization): Factoriza una matriz de datos en dos matrices menores, manteniendo la no negatividad, lo cual es útil para temas y factores interpretables en datos de texto y de imágenes.



Modelos de Mezcla de Gaussiana

GMM (Gaussian Mixture Models): Supone que los datos se generan a partir de una mezcla de varias distribuciones gaussianas. Es útil para modelar datos que tienen subestructuras complejas.



02

Comparación de los Diferentes Enfoques



Cada técnica tiene sus propias ventajas y desventajas, y la elección del enfoque adecuado depende del tipo de datos, el objetivo del análisis y los recursos disponibles.



Clustering

K-Means vs. DBSCAN:

- **K-Means:** Requiere el número de clusters como entrada, es sensible a la inicialización y no maneja bien los clusters con formas no esféricas ni el ruido.
- **DBSCAN:** No requiere número de clusters y puede identificar clusters de formas arbitrarias y detectar ruido, pero puede ser sensible a los parámetros de densidad.

K-Means vs. Clustering Jerárquico:

- **K-Means:** Más rápido y escalable para grandes conjuntos de datos, pero necesita especificar el número de clusters.
- **Clustering Jerárquico:** No requiere especificar el número de clusters, pero puede ser más lento y menos escalable.

Reducción de Dimensionalidad

PCA vs. t-SNE:

- **PCA:** Bueno para reducir la dimensionalidad mientras retiene la varianza global, adecuado para preprocesamiento y modelos predictivos.
- **t-SNE:** Mejor para visualización en 2D/3D, preserva las relaciones locales, pero puede ser lento y no es adecuado para grandes conjuntos de datos.

PCA vs. Autoencoders:

- **PCA:** Lineal, eficiente y fácil de interpretar, pero no captura relaciones no lineales.
- **Autoencoders:** Capaz de capturar relaciones no lineales, flexible, pero más complejo y requiere entrenamiento.

Modelado de Temas

LDA vs. NMF:

- **LDA:** Basado en un modelo probabilístico, puede ser más intuitivo para algunos problemas de modelado de temas, pero puede ser más complejo de ajustar y entrenar.
- **NMF:** Basado en la factorización de matrices no negativas, es más intuitivo para ciertos tipos de datos, pero puede ser menos flexible en algunos casos.

Modelos de Mezcla de Gaussiana

GMM:

- **Versatilidad:** Capaz de modelar distribuciones gaussianas múltiples y encontrar clusters con diferentes formas y tamaños.
- **Complejidad:** Requiere selección de parámetros y puede ser más complejo de ajustar en comparación con métodos más simples como K-Means.

¡Muchas gracias!