


UMAP para Reducción de Dimensionalidad




UMAP (Uniform Manifold Approximation and Projection) es una técnica moderna de reducción de dimensionalidad que ha ganado popularidad debido a su capacidad para preservar tanto la estructura local como la global de los datos, a la vez que ofrece una eficiencia computacional notable. Fue introducida por Leland McInnes, John Healy y James Melville en 2018. ✨



Visualización de Dígitos usando UMAP





Introducción

UMAP es un algoritmo no lineal que utiliza conceptos de geometría algebraica y topología para proyectar datos de alta dimensión en un espacio reducido.

Es capaz de mantener la estructura tanto local como global de los datos, lo que lo hace muy útil para visualizaciones y análisis complejos.

- A diferencia de PCA, que es una técnica lineal, UMAP es capaz de capturar relaciones no lineales en los datos.
- En comparación con t-SNE, UMAP es más rápido y puede manejar grandes conjuntos de datos.


01

Cómo Funciona UMAP

Construcción del Grafo de Vecindad

UMAP comienza construyendo un grafo de vecindad en el espacio de alta dimensión, donde cada punto se conecta a sus vecinos más cercanos.


Este grafo representa las relaciones de proximidad entre los datos.



Transformación en un Espacio de Probabilidad


UMAP modela la similitud entre puntos utilizando una distribución de probabilidad, tanto en el espacio de alta dimensión como en el espacio de baja dimensión.

Esto permite preservar la estructura de vecindad en la proyección final.




Optimización y Minimización de Divergencia

UMAP minimiza la divergencia entre las distribuciones de probabilidad en los espacios de alta y baja dimensión. Este proceso se realiza mediante técnicas de descenso de gradiente para encontrar la mejor proyección.



Conservación de la Estructura Local y Global

UMAP está diseñado para preservar tanto la estructura local como la estructura global de los datos. Esto significa que UMAP es capaz de mantener la proximidad de puntos cercanos, así como las relaciones entre clústeres.



02

Aplicaciones Prácticas de UMAP

Aplicaciones Prácticas de UMAP

Exploración de Datos: UMAP es ampliamente utilizado para la visualización de datos complejos en espacios de baja dimensión, facilitando la identificación de patrones, clústeres y relaciones entre puntos.

Detección de Estructuras: Al proyectar datos a 2D o 3D, UMAP puede ayudar a visualizar y analizar clústeres de datos, proporcionando una vista clara de cómo se agrupan los datos en el espacio reducido.

Embeddings de Palabras y Documentos: UMAP puede ser utilizado para visualizar embeddings de palabras y documentos, lo que ayuda a comprender cómo las palabras y los documentos se agrupan semánticamente.

Aplicaciones Prácticas de UMAP

Visualización de Datos Biológicos: En bioinformática, UMAP se utiliza para explorar datos genómicos y transcriptómicos, ayudando a identificar patrones en la expresión génica y en las relaciones entre genes.

Embeddings de Imágenes: UMAP se aplica a embeddings de imágenes para visualizar cómo diferentes tipos de imágenes se agrupan y se relacionan entre sí.

- **Clasificación y Separación:** Puede ser utilizado para visualizar cómo se separan diferentes clases en un conjunto de datos multiclase, proporcionando una perspectiva intuitiva sobre la capacidad del modelo para distinguir entre clases.

04

Ventajas y Desventajas de UMAP

Ventajas y Desventajas de UMAP

Preservación Global y Local: UMAP puede preservar tanto las estructuras locales como globales en los datos, lo que lo hace útil para una amplia variedad de aplicaciones.

Eficiencia Computacional: UMAP es generalmente más rápido y escalable en comparación con t-SNE, especialmente para conjuntos de datos grandes.

Flexibilidad: UMAP se puede ajustar para capturar diferentes escalas de estructura mediante la configuración de parámetros como el número de vecinos.

Parámetros Sensibles: Los resultados de UMAP pueden depender de la elección de parámetros, como el número de vecinos y el tamaño del vector de embedding.

Interpretación de Resultados: Aunque UMAP facilita la visualización, interpretar los resultados y entender completamente la estructura de los datos puede requerir un análisis adicional.

¡Muchas gracias!